

As implicações metodológicas da Revolução da Credibilidade e Inferência Bayesiana para a pesquisa qualitativa causal

Manoel Galdino

2024-06-30

Abstract

Esta nota tem dois objetivos. Primeiro, sistematizar para a ciência política brasileira a separação entre identificação causal (problema de desenho relativo à população) e inferência estatística (problema de amostra), distinção ainda não incorporada como princípio organizador pela literatura metodológica brasileira. Segundo, especificar o que substitui, em desenhos qualitativos de n pequeno, a infraestrutura de credibilidade da identificação que a revolução da credibilidade fornece para desenhos com múltiplas observações. As tecnologias de desenho — atribuição aleatória, instrumentos, descontinuidades, controle sintético — requerem múltiplas observações para sua operacionalização, e portanto não estão disponíveis em desenhos qualitativos de n pequeno: a objeção ‘e se houver um confundidor não-observado?’ admite suprimimento infinito de variáveis inventáveis sem critério de falseamento. O substituto operacional é a enumeração exaustiva de explicações rivais e a comparação Bayesiana de seus posteriors sob critério de inferência à melhor explicação. Distinguimos a posição aqui defendida da de Spirling e Stewart (2025), que tratam essa inferência como complemento à revolução da credibilidade no passo teórico de toda pesquisa empírica: em desenhos qualitativos de n pequeno, ela é alternativa funcional, e não complemento, porque a infraestrutura de desenho que a revolução da credibilidade pressupõe está indisponível. A objeção de credibilidade contra estudo qualitativo causal deixa de ser ‘e se houver um confundidor não considerado?’ e passa a ser ‘sua enumeração de rivais foi exaustiva?’; o critério de credibilidade migra de plausibilidade de ignorabilidade via desenho para robustez da comparação entre rivais.

1 Introdução

A pesquisa qualitativa em ciência política voltada ao estudo da causalidade é frequentemente percebida como carente de rigor metodológico e de capacidade para isolar efeitos causais quando contrastada com o “template” quantitativo. Essa percepção, recorrente desde King, Keohane, and Verba (1994) (KKV), encontra reforço em trabalhos que apontam fragilidades dos métodos qualitativos para inferência causal — em particular, a dificuldade de descartar explicações alternativas em estudos pequeno- n (Sekhon 2004) e o diagnóstico de que comparações qualitativas seriam tipicamente “inferentially as a weaker and problem-laden equivalent of statistical analysis” (Seawright 2018, 8). As respostas qualitativas a essa percepção — desde Brady and Collier (2010) até desenvolvimentos recentes em process tracing (Collier 2011; Bennett and Checkel 2015) e análise comparativa de casos (Rihoux and Ragin 2009; Ragin 2014) — operaram, em sua maior parte, dentro do quadro inferencial estabelecido por KKV.

Esta nota argumenta que esse quadro foi ele próprio rejeitado pelo desenvolvimento metodológico subsequente da pesquisa quantitativa — a chamada revolução da credibilidade — e que a recepção brasileira do debate metodológico em ciência política e relações internacionais permaneceu, em sua corrente principal, ancorada na moldura inferencial pré-revolução da credibilidade. A contribuição se estrutura em duas camadas.

Primeiro, sistematizamos para a comunidade brasileira a separação entre identificação causal (problema de desenho relativo à população) e inferência estatística (problema de amostra). Essa separação é doutrina consolidada na metodologia quantitativa internacional após a chamada revolução da credibilidade (Angrist and Pischke 2009; Lundberg, Johnson, and Stewart 2021; Imbens 2020; Card 2022), que reorientou a pesquisa quantitativa em torno de tecnologias de desenho — atribuição aleatória, instrumentos, descontinuidades, tendências paralelas, controle sintético — capazes de tornar críveis as suposições de identificação. Na metodologia qualitativa, a separação está em consolidação crescente via duas frentes complementares: a virada Bayesiana, que formaliza o rastreamento de processos (*process tracing*) como atualização de crenças sobre hipóteses causais rivais à luz das evidências (Fairfield and Charman 2022; Humphreys and Jacobs 2023); e a inferência à melhor explicação (Lipton 2004), que articula a credibilidade de uma explicação à luz do conjunto de rivais considerado.

Segundo, e mais original, especificamos o que substitui, em desenhos qualitativos de n pequeno, a infraestrutura de credibilidade da identificação que a revolução da credibilidade fornece para desenhos com múltiplas observações: a comparação Bayesiana de explicações rivais sob critério de inferência à melhor explicação. A objeção “e se houver um confundidor não-observado?”, manobra padrão da crítica de credibilidade, perde poder discriminatório em quali de n pequeno quando formulada de modo abstrato. Postulado sem articulação como explicação rival concreta com implicações empíricas próprias, qualquer confundidor desse tipo é livremente conjecturável e não distingue um estudo bom de um ruim. A pergunta que toma o seu lugar é mais demandante e exige resposta concreta: “sua enumeração de explicações rivais foi exaustiva?”.

O argumento dialoga em particular com Spirling and Stewart (2025), que defendem a inferência à melhor explicação como framework do passo teórico em toda pesquisa empírica em ciência política, posicionando-a como complemento à revolução da credibilidade. Argumentamos que, em desenhos qualitativos de n pequeno, essa inferência é não complemento, mas alternativa funcional — porque a tecnologia de desenho que a revolução da credibilidade pressupõe não está operacionalmente disponível.

Como consequência atravessando as duas camadas, o eixo “ n grande vs n pequeno”, central no debate metodológico pós-KKV, é mal-enquadrado como critério de inferência causal. Identificação e inferência podem operar em qualquer regime de n , sob critérios de credibilidade próprios a cada regime — tecnologias de desenho com múltiplas observações na quanti, comparação Bayesiana de rivais em pequeno- n qualitativo. A comparação metodológica produtiva é entre essas infraestruturas de credibilidade, não entre tamanhos de amostra.

O restante da nota está organizado como segue. A próxima seção mapeia a recepção brasileira do debate metodológico pós-KKV e substancia o gap arquitetural na literatura nacional. A seção seguinte recapitula a revolução da credibilidade e a distinção entre identificação causal e inferência estatística. A seção quatro — centro do argumento — desenvolve o ponto operacional sobre a comparação Bayesiana de rivais como infraestrutura de credibilidade do quali de n pequeno. A seção cinco apresenta a maquinaria Bayesiana mínima e a seção seis revisita duas implementações concretas — *process tracing* Bayesiano e *queries* causais — disponíveis na literatura. A sétima seção elenca limitações práticas da abordagem. A oitava seção é uma ilustração esquemática aplicada ao

impeachment de 2016. As últimas seções tratam de transportabilidade e generalização e oferecem considerações finais.

2 A recepção brasileira do debate metodológico pós-KKV

A recepção da agenda pós-KKV pela ciência política brasileira tem trajetória própria, distinta da rota internacional. Enquanto na fronteira metodológica internacional o debate evoluiu para a separação analítica entre identificação causal (problema de desenho relativo à população) e inferência estatística (problema de amostra) — consolidada na fronteira quantitativa via revolução da credibilidade (Imbens 2020; Lundberg, Johnson, and Stewart 2021; Card 2022) e em consolidação crescente na fronteira qualitativa via virada Bayesiana (Fairfield and Charman 2022; Humphreys and Jacobs 2023) e inferência à melhor explicação (Lipton 2004) —, a literatura metodológica brasileira em ciência política e relações internacionais permaneceu, em sua corrente principal, dentro da moldura inferencial pós-KKV (King, Keohane, and Verba 1994; Brady and Collier 2010), em que desenho de pesquisa, identificação causal e estimação estatística figuram como componentes interdependentes de um mesmo problema unificado de “produção de inferências válidas”.

A figura central dessa síntese metodológica é Flávio da Cunha Rezende, com a agenda do Pluralismo Inferencial pós-KKV (da Cunha Rezende 2017, 2019): pluralização *interna* ao framework KKV, em que múltiplas lógicas de causação coexistem para a produção de inferências válidas, sem que a separação entre identificação e estimação seja tematizada como movimento próprio. A mesma moldura organiza a literatura didática (Mesquita 2017; Leite and Rocha 2019; Figueiredo Filho et al. 2021) e a aplicação metodológica em subdisciplinas (Paula 2018). Bibliometricamente, Figueiredo Filho et al. (2021) documentam o crescimento da expressão “inferência causal” na produção brasileira da última década, mas o termo é mobilizado como sinônimo de “estabelecer causa de modo válido”, não como conceito técnico do par identificação/inferência.

A ilustração mais clara da arquitetura conceitual instalada está no manual mais recente de desenho de pesquisa para a comunidade brasileira (Silva 2023, ENAP/DCP-USP). O texto importa termos do vocabulário moderno — usa “estratégias de identificação” e apresenta competentemente *regression discontinuity*, *propensity score matching*, controle sintético e diferença-em-diferenças com a intuição correta —, mas a seção sobre causalidade é organizada em torno do pluralismo filosófico

de Brady (2008), não de Pearl ou Rubin formalizados; e a seção sobre desenhos qualitativos de *n* pequeno opera em vocabulário Vennesson-Rueschemeyer-Mill, sem citar uma única vez Bayes, *process tracing* nomeado, ou os trabalhos de Fairfield-Charman, Humphreys-Jacobs, Bennett-Checkel ou Beach-Pedersen. O gap brasileiro, portanto, não é de vocabulário — alguns termos chegaram —, mas de arquitetura conceitual: o split identificação $\neq$ inferência ainda não funciona como princípio organizador da pedagogia metodológica brasileira, e a virada Bayesiana qualitativa simplesmente não está no horizonte do treinamento de pós-graduação.

Há avanços parciais que merecem registro. da Cunha Rezende (2011) reconhece explicitamente que pesquisa qualitativa de *n* pequeno exige pressupostos e conceitos distintos das técnicas tradicionais de regressão, uma versão fraca do split sem completar o movimento conceitual. Sposito, Gabriel, and Artioli (2022) organizam seleção de casos em torno de tipos de alegação causal — probabilística, mecanística, conjuntista —, um movimento explicitamente *design-first* na linha do que a revolução da credibilidade faz no quanti, mas sem mobilizar o vocabulário formal Pearl/Rubin nem a comparação Bayesiana de rivais. Vick and Gurza Lavalle (2020) aplicam *process tracing* à efetividade de conferências participativas, distinguindo operacionalmente “rastreo de mecanismo” de “análise correlacional” — sem tematizá-lo, contudo, como categoria metodológica nomeada. Perissinotto (2024) contrasta “data-set observation” e “causal-process observation” para defender a combinação de QCA com *process tracing*. São precedentes brasileiros consistentes com a direção conceitual desta nota, mas sem articular o split como princípio organizador.

Vale explicitar como o split conceitual reorganiza um problema central da literatura quali pós-KKV: a seleção de casos. Sob a separação aqui adotada — identificação causal como propriedade populacional do desenho, inferência estatística como problema de amostra $\rightarrow$ população —, o problema da seleção de casos se decompõe em três subproblemas distintos que KKV (King, Keohane, and Verba 1994) deixaram unidos: (i) selecionar pelo valor da variável dependente pode induzir viés de colisor (Pearl and Bareinboim 2011), problema **estrutural do desenho** que demanda evitar condicionar em *Y* ou justificar que *Y* não é colisor relevante; (ii) selecionar de modo não-aleatório limita o que se pode concluir sobre populações alheias aos casos selecionados, problema de validade externa, separado de identificação; (iii) tamanho pequeno de amostra afeta a precisão da inferência estatística condicional à identificação, problema separado dos dois primeiros. KKV operam com uma “lógica

única de inferência” que não separa identificação de inferência estatística e fundem (i), (ii) e (iii) sob a rubrica de *selection bias*; Sposito, Gabriel, and Artioli (2022), seguindo a tipologia de Koivu and Damman (2015), absorvem essa fusão e a reorganizam em famílias de “lógicas próprias de seleção” (EQ/PE/TC). Decompostos, os três problemas têm respostas distintas: (i) é problema de desenho — nem a comparação Bayesiana de rivais o resolve, porque o caminho não-causal aberto faz com que a evidência condicionada deixe de discriminar entre os mecanismos alternativos; (ii) e (iii) são logicamente independentes da identificação, e a relevância de cada um depende do que se pretende concluir, não da seleção em si.

A reorganização em EQ/PE/TC carrega outras confusões além da fusão KKV. Sposito, Gabriel, and Artioli (2022) apresentam validade interna e validade externa como tradeoff: a primeira “vem às custas” da segunda; a primeira é virtude do quali, a segunda das pesquisas quantitativas. Sob o paradigma de resultados potenciais aqui adotado, as duas são propriedades distintas e não-substituíveis: validade interna depende da credibilidade das suposições de identificação, validade externa da teorização do escopo de aplicação. Para “diminuir essa desvantagem” da generalização em pequeno- n , os autores propõem identificar um *universo causal homogêneo* dentro do qual a relação causal generaliza com *lógica determinista* — movimento que combina dois passos próprios da moldura pré-revolução-da-credibilidade: a redefinição de escopo para preservar generalização (instância do mesmo padrão criticado adiante, na seção sobre transportabilidade) e a invocação da dicotomia ontológica deterministic-vs-probabilistic, dispensável sob resultados potenciais que admitem heterogeneidade entre unidades sem necessidade de tomar partido sobre a fonte da aleatoriedade. A própria tipologia tripartite — Emulação Quantitativa (probabilística), Pragmatismo Eclético (mecanística), Teoria de Conjuntos (set-teorética) — projeta a divisão deterministic-vs-probabilistic como se houvesse ontologias causais distintas em jogo. Sob o paradigma adotado nesta nota, as três famílias correspondem a vocabulários distintos de uma mesma estrutura inferencial: efeitos potenciais heterogêneos comparados via hipóteses rivais sob inferência à melhor explicação. As “lógicas próprias” são vestidos da mesma máquina.

A ausência mais notável é a da inferência Bayesiana qualitativa: nenhum trabalho metodológico publicado em periódico brasileiro de ciência política ou relações internacionais nos últimos quinze anos articula, como objeto teórico próprio para a disciplina, a separação identificação/inferência

tal como a fronteira metodológica internacional a estabeleceu, ou propõe a comparação Bayesiana de explicações rivais como infraestrutura de credibilidade para desenhos de n pequeno. É esse o gap que esta nota busca preencher: tradução para a comunidade brasileira do split conceitual já consolidado lá fora, com o ponto operacional próprio sobre como o critério de credibilidade migra, em quali de n pequeno, do controle de variáveis omitidas via desenho para a comparação Bayesiana de explicações rivais.

3 Revolução da Credibilidade

A revolução da credibilidade na economia (Forozish 2024; Goldsmith-Pinkham 2024; Angrist and Pischke 2010) impactou várias disciplinas que lidam com dados observacionais (Lundberg, Johnson, and Stewart 2021; Libman 2023; Glied 2021), incluindo a ciência política (Samii 2016; Keele 2015b, 2015a; Grimmer 2015). Um dos trabalhos pioneiros que estabeleceram a agenda para essa revolução é o artigo de Leamer (1983), “Let’s take the con out of econometrics”, onde o autor critica a prática padrão de especificações econométricas múltiplas para controlar vieses de variável omitida, argumentando que tais práticas não produzem resultados confiáveis.

Respondendo ao desafio de Leamer, vários autores desenvolveram desenhos de pesquisa com suposições mais críveis e transparentes (Card 2022; Angrist and Pischke 2010, 2009; Angrist and Krueger 1991; Card and Krueger 1994). Esses estudos buscaram assegurar que os efeitos causais fossem reais e se aproximassem dos resultados de experimentos aleatórios controlados, elevando o padrão de inferência causal (Rubin 1974).

3.1 Identificação Causal

Identificação causal refere-se à capacidade de um desenho de pesquisa estimar um estimando específico, como o efeito causal médio (ATE - Average Treatment Effect) ou o efeito do tratamento sobre os tratados (ATT - Average Treatment on the Treated). A identificação não depende do tamanho da amostra, mas sim do desenho da pesquisa e de suposições críveis. Tipicamente, definimos causalidade para a unidade ou indivíduo i como sendo a diferença entre dois resultados potenciais (no caso de um tratamento binário): $Y_i(1) - Y_i(0)$, em que $Y_i(1)$ indica o resultado potencial para o

indivíduo se recebeu o tratamento, $Y_i(0)$ se não recebeu (grupo controle).

Resultados potenciais admitem heterogeneidade entre unidades — $Y_i(0)$ e $Y_i(1)$ podem variar livremente entre indivíduos —, e estimandos populacionais como o ATE são médias dessas diferenças individuais. Adotamos essa formulação como pressuposto operativo, sem tomar partido sobre a fonte ontológica da aleatoriedade subjacente, questão filosófica que não discrimina entre os argumentos desta nota.

Para que estimandos como o ATE sejam identificados — isto é, estimáveis mesmo com quantidade infinita de dados —, é necessária alguma suposição adicional. A mais típica é conhecida como “ignorability” forte, cuja exigência central é que a atribuição do tratamento seja independente dos resultados potenciais, ou seja, as unidades não selecionam o tratamento com base nos seus potenciais benefícios (ou malefícios).

Considere o exemplo do incêndio domiciliar (Mackie 1965; Sposito, Gabriel, and Artioli 2022). As causas candidatas são variáveis binárias — chama de fósforo F , folhas secas L , oxigênio O , raio R , telhado inflamável T , curto-circuito C , fiação inflamável W . A configuração “INUS” afirma que o incêndio $Y = 1$ se, e somente se, uma das conjunções $(F \wedge L \wedge O)$, $(R \wedge T)$, ou $(C \wedge W)$ for verdadeira. No vocabulário de resultados potenciais, isso é simplesmente a função estrutural $Y = (F \wedge L \wedge O) \vee (R \wedge T) \vee (C \wedge W)$ — um DAG com F, L, O, R, T, C, W apontando para Y e essa equação como mecanismo (Figura 1). O que o vocabulário set-teorético chama de “condição INUS” é, em resultados potenciais, o status de cada X_i numa decomposição disjuntiva-conjuntiva da função estrutural: particular, mas não exótica nem fora do paradigma. Causas SUIN admitem tradução análoga.

Mais importante: a tradução expõe um ponto que o vocabulário set-teorético tende a obscurecer. Mesmo com a estrutura conhecida — inclusive a forma INUS bem identificada —, a análise profunda do caso pode confundir uma das causas com uma variável omitida U . Se a fiação parece danificada, a pesquisadora pode atribuir o incêndio a C quando o causador foi U não-considerado (vandalismo, defeito de fábrica do material). A análise profunda *per se* não protege contra esse erro; o que protege é considerar “foi U , não C ” como hipótese rival explícita e submetê-la à comparação Bayesiana — que é a infraestrutura de credibilidade desenvolvida no restante deste trabalho.




Figure 1: DAG do exemplo do incêndio. Função estrutural: $Y = (F \wedge L \wedge O) \vee (R \wedge T) \vee (C \wedge W)$. As variáveis binárias correspondem a fósforo aceso (F), folhas secas (L), oxigênio (O), raio (R), telhado inflamável (T), curto-circuito (C) e fiação inflamável (W).

4 De variável omitida a explicação rival: a credibilidade da identificação em n pequeno

Identificação causal é, conforme estabelecido na seção anterior, uma propriedade do desenho de pesquisa relativa à população: dado um desenho que satisfaça as suposições de identificação, o estimando é recuperável de uma quantidade infinita de dados gerados por aquele desenho, independentemente do tamanho da amostra observada. A contribuição original da revolução da credibilidade (Imbens 2020; Lundberg, Johnson, and Stewart 2021; Card 2022) foi tornar transparente que essas suposições precisam ser defendidas como críveis no caso concreto, e que alguns desenhos de pesquisa sustentam mais credibilidade do que outros de que não há uma variável omitida invalidando a suposição de ignorabilidade. A randomização aleatoriza a atribuição do tratamento e, sob SUTVA e adesão completa, sustenta a ignorabilidade do tratamento recebido; instrumentos deslocam a defesa para suposições de relevância e exclusão; descontinuidades de regressão localizam a comparação numa vizinhança estreita do *cutoff*; tendências paralelas e doadores sintéticos a justificam por inspeção empírica de períodos pré-tratamento. Cada uma dessas tecnologias requer múltiplas observações para sua operacionalização: a randomização opera sobre uma amostra de unidades de tratamento e controle; instrumentos exigem variação no instrumento entre unidades; descontinuidades requerem unidades de cada lado do *cutoff*; tendências paralelas pressupõem ao

menos dois períodos para múltiplos grupos; controle sintético constrói o contrafactual a partir de um *donor pool*.

Antes de prosseguir, vale enquadrar a contribuição em termos de validade. Resultados potenciais permitem heterogeneidade de efeitos: o efeito de X sobre Y pode variar entre unidades, com cada unidade i tendo seus próprios $Y_i(0)$ e $Y_i(1)$. Heterogeneidade torna a transportabilidade entre populações um problema empírico não-trivial — extrapolar o estimando de uma amostra para outra exige justificativa substantiva sobre os modificadores do efeito (Pearl and Bareinboim 2011). A validade interna, por sua vez, não decorre de heterogeneidade nem de profundidade descritiva: a possibilidade de que uma variável omitida U confunda X e Y persiste em qualquer estudo cujo desenho não a exclua, e a reconstrução qualitativa rica do caso pode coexistir com falha de identificação. A solução do *quali de n pequeno* para o problema do confundidor não-observado postulado abstratamente se dá pela comparação Bayesiana de explicações rivais sob critério de inferência à melhor explicação, conforme desenvolvido a seguir. Problemas estruturais do desenho — viés de colisor em estudos que condicionam em Y , por exemplo — exigem solução de desenho, não de inferência.

Em desenhos qualitativos de *n pequeno* — $N = 1$, $N = 2$, $N = 3$ — as tecnologias de identificação descritas no parágrafo de abertura não estão operacionalmente disponíveis. Isso não significa que a identificação causal seja conceitualmente diferente em *quali de n pequeno*: o estimando ainda é definível conforme as suposições de identificação, e a separação entre identificação (problema de desenho relativa à população) e inferência estatística (problema de amostra) preservada. O que muda é o repertório disponível de tecnologias para fundamentar a credibilidade dessas suposições. A objeção padrão da revolução da credibilidade — “e se houver uma variável U não-observada que confunde o efeito de X sobre Y ?” — admite, em *quali de n pequeno*, suprimento ilimitado de variáveis inventáveis: para qualquer estudo de caso particular, é sempre possível conjecturar mais um U plausível em princípio. Nessa forma — postulado abstratamente, sem articulação como explicação rival concreta com implicações empíricas próprias — qualquer U é universalmente aplicável a qualquer estudo e por isso não discrimina entre estudos bons e ruins. Resumido: a infraestrutura de credibilidade da ignorabilidade que a revolução da credibilidade fornece para desenhos com múltiplas observações não tem equivalente direto disponível em desenhos qualitativos de *n pequeno*.

4.1 A objeção de credibilidade muda de forma

O que substitui essa objeção, na prática efetiva da pesquisa qualitativa de n pequeno, é uma objeção mais demandante e mais informativa: sua enumeração de explicações rivais foi exaustiva? Há alguma hipótese causal sustentada pela literatura, ou plausível à luz dos dados, que você não considerou e que poderia explicar o mesmo padrão de evidências? Essa objeção é refutável — basta apresentar a explicação rival omitida e mostrar que sua inclusão muda a comparação — e produtiva: a resposta amplia o conjunto de explicações comparadas e melhora o estudo. A finitude do conjunto de rivais é, ela mesma, parte do que confere força ao critério: um conjunto que se expande continuamente diante de qualquer desafio empírico esvazia a comparação.

A reformulação encontra eco em vertentes recentes da metodologia qualitativa. Slater and Ziblatt (2013) já argumentavam que o método comparativo controlado serve para distinguir entre hipóteses rivais principais, e não para estimar o efeito causal de uma explicação singular. Fairfield and Charman (2022) e Humphreys and Jacobs (2023) oferecem dois aparatos formais — *process tracing* Bayesiano e modelo de *queries* causais — que implementam essa comparação via *posterior odds* sob a regra de Bayes, e cuja arquitetura comum é a inferência à melhor explicação de Lipton (2004). E Spirling and Stewart (2025), em trabalho recente em ciência política, defendem que a inferência à melhor explicação é o framework do passo teórico em toda pesquisa empírica e observam que a credibilidade da inferência causal depende tanto da exaustividade do conjunto de rivais considerados quanto da qualidade das evidências que comparam entre eles.

4.2 Duas tecnologias, dois critérios de credibilidade

A passagem do quanti com n grande para o quali de n pequeno não é, portanto, perda de rigor causal: é mudança no *critério* de rigor causal. Em quanti com n grande, a tecnologia disponível é o desenho que torna plausível a ignorabilidade; o critério de credibilidade é a plausibilidade dessa suposição. Em quali de n pequeno, a tecnologia disponível é a comparação Bayesiana de hipóteses rivais sob critério de inferência à melhor explicação; o critério de credibilidade é a robustez da enumeração de rivais e a magnitude da comparação de *posteriors*. As duas tecnologias respondem a uma mesma pergunta — *como sabemos que essa é a explicação correta?* — mas operam sob restrições distintas e produzem contas distintas.

É importante separar com cuidado o que essa mudança de critério faz e o que não faz. Ela não elimina, no sentido formal quantitativo, o problema do viés de variável omitida: continua matematicamente verdadeiro que se uma variável U afeta causalmente Y e covaria com X no conjunto de casos analisados, então a hipótese $X \rightarrow Y$ tal como inicialmente formulada não corresponde ao efeito causal sem viés (Morgan and Winship 2015). O que a comparação de rivais faz é *reformular* o problema: o U relevante torna-se uma das hipóteses rivais a ser explicitamente colocada no conjunto e comparada via *posterior odds*. Se a evidência é mais compatível com a hipótese $X \rightarrow Y$ do que com qualquer hipótese envolvendo U , a inferência ganha apoio à luz do conjunto considerado; se a evidência é igualmente compatível, ou mais compatível com U , a inferência é fraca. Esse é o sentido em que a credibilidade migra de “plausibilidade de ignorabilidade via desenho” para “robustez da comparação de rivais”: não há ignorabilidade a postular sem evidência, mas há evidência a comparar entre rivais.

4.3 Distinção a Spirling & Stewart (2025)

A posição mais próxima da nossa na literatura recente é a de Spirling and Stewart (2025). Eles argumentam que a inferência à melhor explicação é o framework do passo teórico em toda pesquisa empírica em ciência política, inclusive em estudos com identificação rigorosa via revolução da credibilidade. Em sua leitura, mesmo um experimento perfeitamente identificado entrega “um fato confiável sobre o mundo” cuja interpretação teórica ainda exige separar a explicação preferida de explicações rivais. A revolução da credibilidade fornece a infraestrutura de credibilidade da identificação; a inferência à melhor explicação é o framework do passo seguinte — da inferência identificada para a explicação. A inferência à melhor explicação, em sua leitura, *complementa* a revolução da credibilidade.

Nosso argumento estende e diverge desse. Em pesquisas observacionais com múltiplas observações, a infraestrutura de credibilidade via tecnologia de desenho continua disponível e a inferência à melhor explicação complementa o passo teórico, como Spirling e Stewart defendem. Em qual de n pequeno, ao contrário, essa infraestrutura não está disponível: a inferência à melhor explicação não é complemento, mas *alternativa funcional*. Não há uma etapa de defesa da credibilidade da ignorabilidade via desenho cuja qualidade poderíamos avaliar separadamente da comparação de

rivais. A enumeração de rivais e a comparação Bayesiana de seus *posteriors* são a infraestrutura de credibilidade do estudo. Spirling e Stewart, focados em regressão, deixam esse caso explicitamente aberto: em rodapé, observam que “uma versão do que argumentamos aplica-se mais geralmente, *e.g.*, a evidência qualitativa”. É exatamente o espaço onde esta nota contribui.

4.4 A seleção de casos, decomposta

A separação entre identificação e inferência estatística permite tratar a “seleção de casos” sem confundir três problemas que KKV (King, Keohane, and Verba 1994) deixaram unidos. **Selecionar pelo valor da variável dependente** pode induzir viés de colisor (Pearl and Bareinboim 2011): condicionar em Y abre um caminho não-causal entre X e variáveis omitidas. É problema **estrutural do desenho** que não muda com tamanho de amostra: em estudo de $N = 1$ ou $N = 1000$, sob colisor aberto a evidência condicionada deixa de discriminar entre os mecanismos causais alternativos, e nenhuma comparação Bayesiana de explicações rivais resolve o problema. A solução é desenhar para não condicionar em Y , ou justificar via análise estrutural que Y não é colisor entre X e as variáveis omitidas relevantes. **Selecionar de modo não-aleatório**, por sua vez, é problema de inferência amostra $\rightarrow$ população: limita o que se pode concluir sobre populações alheias aos casos selecionados — questão de validade externa, separada de identificação. **Tamanho pequeno de amostra** afeta a precisão da inferência estatística condicional à identificação, e é absorvido pela inferência Bayesiana desenvolvida adiante. A lógica causal é a mesma nos três regimes. Card and Krueger (1994) compararam New Jersey e Pensilvânia sem pretensão de representatividade do conjunto de estados americanos; Abadie, Diamond, and Hainmueller (2015) estudam o efeito da reunificação sobre o produto da Alemanha Ocidental usando uma única unidade tratada e um *donor pool* de outros países da OECD. Nem Card e Krueger nem o estudo da reunificação são acusados de “selecionar pela variável dependente”: escolhem casos pelo **tratamento** (aumento do salário mínimo; ocorrência da reunificação) e adicionam contrafactual (estado vizinho; *donor pool* sintético); Y é o salário/produto, não a presença ou ausência do tratamento. A credibilidade desses estudos repousa exclusivamente sobre a defensabilidade das suposições de identificação — tendências paralelas para o par NJ-PA, comparabilidade do *donor pool* para a Alemanha — para os casos escolhidos. A mesma lógica organiza desenhos qualitativos pequeno- n : tamanho de amostra ou ausência de aleatoriedade não introduzem epistemologia adicional.

5 Soluções Práticas para Inferência em Amostras Pequenas

Estabelecida a comparação de hipóteses rivais como tecnologia de credibilidade do qual de n pequeno, segue a questão de como operacionalizá-la. Como quantificar, de forma rigorosa, a incerteza sobre hipóteses concorrentes a partir de pequenas amostras de evidência? A resposta é a estatística Bayesiana, que introduzimos a seguir.

5.1 Inferência Bayesiana

Na estatística Bayesiana, a quantificação da incerteza depende de uma distribuição de probabilidade a priori, que usualmente é interpretada como a incerteza da pesquisadora antes de observar evidência empírica, e uma verossimilhança, que é uma modelagem do processo de geração de dados. O teorema de Bayes, que dá nome à abordagem estatística, nos diz como combinar de maneira rigorosa a priori e a verossimilhança, para obtermos uma distribuição de probabilidade a posteriori (isto é, após observar a evidência empírica) sobre as quantidades de interesse. Não há diferença formal entre n pequeno ou grande. O impacto do tamanho amostral é apenas em reduzir a incerteza a posteriori. É possível mostrar que, sob condições bastante gerais de regularidade, a distribuição a posteriori converge para a distribuição verdadeira à medida que o tamanho amostral vai para infinito. Em outras palavras, a incerteza se reduz com n maior, mas a rigor nada impede de se estimar qualquer quantidade de interesse com um n pequeno.

Na verdade, a questão crítica para a inferência estatística não é simplesmente o tamanho da amostra (n), mas também a relação sinal-ruído; ou seja, quanto mais forte o efeito (o “sinal”) em relação ao ruído (variabilidade dos dados), menos dados são necessários para detectá-lo.

Não é por outra razão que estudos qualitativos bem desenhados geralmente se concentram em contextos onde o sinal é forte e claramente observável, permitindo inferências robustas mesmo com menos casos. Esse tipo de estratégia visa resolver problemas de inferência, mas nada dizem sobre a validade interna, que estão relacionadas às condições formais de identificação.

Por outro lado, estudos quantitativos com grandes amostras podem ser necessários para detectar efeitos menores, onde o sinal é fraco em relação ao ruído. Portanto, a crítica ao tamanho da amostra na verdade é imprecisa, pois é preciso combinar o tamanho amostral com a razão sinal-ruído, para

só então avaliar qual tipo de desenho de pesquisa deve produzir menor incerteza inferencial. Sem analisar o caso concreto, nada pode ser dito sobre um tipo de pesquisa ou outro.

E a abordagem Bayesiana é uma das formas pela qual se pode quantificar essa relação sinal-ruído e tamanho amostral. Se o sinal for muito fraco para um dado tamanho amostral, haverá reflexo na quantificação da incerteza que será muito elevada. Se por outro lado o sinal for forte o suficiente para o dado número de casos, a incerteza estimada permitirá inferências e conclusões mais assertivas.

Brevemente: o teorema de Bayes — $p(H | E) \propto p(H) p(E | H)$ — fornece a regra para atualizar crenças sobre hipóteses à luz de evidências, em que $p(H)$ é a probabilidade *a priori* da hipótese, $p(E | H)$ a verossimilhança (quão esperada a evidência seria sob a hipótese) e $p(H | E)$ a probabilidade *a posteriori* (a credibilidade da hipótese após a evidência). O leitor não familiarizado com a maquinaria Bayesiana encontrará introduções acessíveis em manuais clássicos da estatística Bayesiana e, para o uso específico em pesquisa qualitativa, em Fairfield and Charman (2022).

6 Novos Desenhos Causais Qualitativos

Para que a inferência Bayesiana possa ser útil, é preciso que o desenho de pesquisa seja crível para responder a perguntas causais. Nesta seção, apresentaremos duas soluções recentes que utilizam a metodologia Bayesiana para estimar quantidades causais em pesquisas qualitativas: uma desenvolvida no livro *Integrated Inferences* de Humphreys and Jacobs (2023) (ver também Humphreys and Jacobs (2015)) e outra no livro *Social Inquiry and Bayesian Inference* de Fairfield and Charman (2022) (ver também Fairfield and Charman (2019); Fairfield and Charman (2017)).

Essas soluções tornam concreto o argumento desta nota de que o problema de identificação é logicamente distinto do problema da inferência estatística, e o caminho operacional para a credibilidade da identificação em quali de n pequeno não é a tecnologia de desenho da revolução da credibilidade, mas a comparação Bayesiana de explicações rivais.

6.1 Process Tracing Bayesiano

O rastreamento de processos bayesiano é uma abordagem robusta para inferência causal em estudos qualitativos. Utilizando a probabilidade bayesiana, podemos atualizar nossas crenças sobre hipóte-

ses causais à medida que novas evidências são coletadas. Este método é particularmente útil em contextos onde as evidências são escassas ou os processos causais são complexos.

Assim, envolve a especificação de hipóteses H_i e suas probabilidades a priori $P(H_i)$. Deve-se identificar as evidências disponíveis e construir a verossimilhança $P(E|H_i)$ para cada hipótese. As comparações de hipóteses são feitas usando as *odds* a posteriori, de forma a não precisa computar a constante normalizadora:

$$\frac{P(H_i|E)}{P(H_j|E)} = \frac{P(H_i)P(E|H_i)}{P(H_j)P(E|H_j)}$$

A seguir explico como cada um dos componentes da fórmula acima (priori e verossimilhança) são formulados na prática.

6.1.1 Definição de Prioris

A definição de prioris pode ser feita por meio da elicitación de experts, uso de prioris não-informativas e prioris informativas definidas pela pesquisadoras.

A elicitación de experts envolve a consulta a especialistas e utilização de métodos para transformar o conhecimento deles em distribuições de probabilidade. Como tais pessoas não costumam saber traduzir seus conhecimentos em distribuição de probabilidade, a literatura dessa área tem desenvolvido métodos para extrair esse conhecimento e quantificá-lo em distribuições de probabilidade (O'Hagan (2019), Albert et al. (2012), O'Hagan et al. (2006), O'Hagan (1998)).

Prioris não-informativas são a forma mais básica e tradicional de definição de prioris (O'Hagan 2010). A ideia é escolher uma priori que torne todas as hipóteses a priori igualmente prováveis, seguindo o princípio da razão insuficiente (Kass and Wasserman 1996).

Uma terceira possibilidade é o uso de prioris informativas, que representem o conhecimento da pesquisadora, que pode advir de conhecimento substantivo ou de resultados de pesquisas prévias como meta-análises ou estudos quantitativos prévios (Gelman, Simpson, and Betancourt 2017; Gelman 2009).

Como argumenta Bouchat (2023), essa parte do livro é muito menos desenvolvida que a da con-

strução da verossimilhança. Há potencial para avançarmos nessa parte, especialmente porque a priori pode servir como uma fonte de regularização, de maneira similar ao Double LASSO em machine learning adaptada para inferência causal (Urminsky, Hansen, and Chernozhukov, n.d.). Por ora, o esperado é a utilização de prioris não-informativas, para evitar o risco que a pesquisadora utilize prioris infladas ou uma espécie de viés de confirmação. Por outro lado, a vantagem é que as prioris são transparentes e permitem colocar em termos claros onde há possível discordância. Além disso, é possível (e recomendável) fazer uma análise de robustez com outras prioris, para avaliar se e como as conclusões mudam.

6.1.2 Verossimilhanças

A verossimilhança avalia a plausibilidade de observar uma evidência E sob a hipótese H_i . Os autores recomendam adaptar a ideia de decibéis, que utilizamos para classificar o volume de um som, para avaliar o peso de uma evidência. Ou seja, deveríamos usar logaritmos (os decibéis são calculados com logaritmos) para calibrar o peso das evidências:

$$10 \log_{10} \left(\frac{P(E|H_i)}{P(E|H_j)} \right)$$

Para ver a utilidade de se utilizar decibéis para ponderar o peso das evidências, os autores analisam um exemplo introduzido por Bennett and Checkel (2015), no qual se considera um *smoking gun* se $P(E|H_j) = 0,05$ e $P(E|H_i) = 0,2$. Aplicando o logaritmo, isso dá cerca de 6 dB. Segundo Fairfield and Charman (2017), um volume de 6 dB é saliente, mas estaria longe de ser um *smoking gun*.

É importante destacar que a verossimilhança não pode contaminar a priori. Ou seja, informações que são na verdade evidências que entrariam na verossimilhança não podem ser utilizadas para formar prioris.

6.1.2.1 Evidências Na análise estatística tradicional, é em geral simples determinar quando uma observação termina e outra começa. No caso de estudos qualitativos, em especial rastreamento de processo, esse passo é menos trivial.

A definição de evidências é crucial e pode incluir informações de diferentes fontes ou observações

correlacionadas. No Bayesianismo, podem ser consideradas evidências de outros casos similares. Evidências devem ser suficientemente distintas para favorecer hipóteses diferentes.

6.1.3 Hipóteses Rivais

A formulação de hipóteses rivais ajuda a reduzir o viés de confirmação (Fairfield and Charman 2019). Matematicamente, duas hipóteses rivais significam que $P(H_i) + P(H_j) = 1$. Se a pesquisa possui uma única hipótese, é fácil avaliar erroneamente se determinada evidência empírica torna a hipótese mais ou menos plausível. Digamos que estamos interessados em investigar as causas de um acidente de avião¹. Se minha única hipótese é que foi apenas falha mecânica, e encontramos evidências de que a caixa preta do avião registrou altitude errada e que o piloto não tinha dormido nas últimas 24 horas. A primeira evidência suporta a hipótese, enquanto a segunda é neutra. Porém, suponha que a outra hipótese (rival) é que houve uma falha mecânica e falha humana em conjunto. Nesse caso, a primeira hipótese parece menos plausível do que a segunda.

Não basta simplesmente formular uma negação lógica, pois ela inclui infinitas hipóteses potencialmente contraditórias entre si. Ou seja, não basta dizer que uma hipótese é que houve apenas falha mecânica e a hipótese rival é que não houve apenas falha mecânica, pois a negação aqui inclui houve falha humana e não houve falha humana.

Uma das limitações da abordagem de rastreio de processo Bayesiana é quando a pesquisadora considera a possibilidade de múltiplas causas, pois pode ser difícil formulá-las como hipóteses rivais. Mas esse é um passo necessário para que a metodologia possa ser empregada.

A ideia de hipóteses rivais é crítica para estabelecer o tipo de pesquisa causal que em geral é possível na metodologia qualitativa. Como vimos, um desafio é garantir que não há variável omitida relevante. Para Slater and Zibblatt (2013), o possível é avaliar a plausibilidade relativa de hipóteses principais, o que condiz com a sugestão de comparar *posterior odds* de Fairfield and Charman (2022).

Trabalhos clássicos do método comparativo histórico — Skocpol (1979) sobre revoluções é exemplo notório — já operavam, em substância, sob essa lógica de comparação de explicações rivais, ainda que sem o aparato Bayesiano explícito. A formalização que process tracing Bayesiano e

¹Agradeço à Elizabeth Balbachevsky pela sugestão do exemplo

queries causais oferecem é a explicitação dos pesos relativos das evidências e a possibilidade de análise de robustez quantitativa, não a invenção da prática.

A consequência metodológica principal é que estudos de caso com uma única hipótese a ser testada são fracos não pelo tamanho da amostra, mas pela ausência de comparação informativa: a “hipótese rival” reduzida à negação lógica abre o espaço para qualquer variável omitida concebível, contra a qual nenhuma evidência específica pode discriminar. Conforme estabelecido em seção anterior, a comparação Bayesiana de rivais não *elimina* a possibilidade de variáveis omitidas no sentido formal quantitativo; *reformula* a objeção: a variável omitida candidata vira uma das hipóteses no conjunto a ser comparado, e a credibilidade do estudo passa a depender da exaustividade desse conjunto.

6.2 Inferências Integradas

O trabalho de Humphreys and Jacobs (2023) apresenta o que eles chamam de *queries* causais, que consiste na utilização de Directed Acyclic Graphs (DAGs), tal como desenvolvida por Pearl, juntamente com inferência Bayesiana, para estimar quantidades causais com métodos qualitativos. O termo inferência integrada é porque, ao utilizar metodologias originariamente quantitativas, permite integrar quali-quant, produzindo assim desenhos de pesquisa com métodos mistos. Aqui interessa para nós o aspecto qualitativo da abordagem.

Um primeiro aspecto que a metodologia de Humphreys and Jacobs (2023) deixa claro é que é necessário, para fins práticos, considerar todas as variáveis da pesquisa quali como binárias. Isso faz sentido, posto que seria inviável mensurar quantidades contínuas e relacioná-las estatisticamente com amostras pequenas. Ou seja, a variância potencial seria muito grande, tornando inviável a estimação.

Um segundo aspecto é que, como é costumeiro, é mais fácil modelar as relações causais como determinísticas, ou seja, um caso possui ou não relação causal entre variáveis, não cabendo pensar probabilisticamente. Isso, contudo, não é uma limitação muito relevante, pois a quantificação da incerteza via Bayes significa que poderemos falar de probabilidade do efeito causal existir. Ou seja, a relação é determinística, mas o nosso conhecimento sobre a relação causal é probabilístico, o que é compatível com boa parte das ontologias sociais.

A suposição de que a relação causal é determinística e binária leva a ideia de que cada caso pode ser classificado em um tipo causal. Os tipos causais podem ser classificados em quatro categorias: adverso, benéfico, crônico e destinado. Cada tipo representa uma relação causal distinta entre tratamento e resposta. Por exemplo, indivíduos adversos melhorariam apenas se não recebessem o tratamento, enquanto os benéficos melhorariam apenas se o recebessem. Os crônicos permanecerão doentes independentemente do tratamento, e os destinados melhorarão independentemente do tratamento. Esse modelo pode ser facilmente generalizado para múltiplas causas, com uma pequena modificação na notação, a qual o leitor interessado pode encontrar no livro de Humphreys e Jacobs.

Para aplicar essa estrutura teórica, utilizamos modelos de queries causais. Esses modelos nos permitem investigar efeitos causais médios, causas ao nível de casos (case-level causal analysis) e caminhos causais. Uma query causal é um algoritmo que recebe um modelo M como entrada (especificado na forma de um DAG) e retorna uma quantidade $Q(M)$ como saída. Existem quatro queries causais chave que são fundamentais para essa análise e respondem a questões distintas: - Efeitos causais ao nível de caso (case-level). - Atribuição causal ao nível de caso. - Efeitos causais médios (ATE). - Caminhos causais.

6.2.1 Efeito Causal ao Nível do Caso

Perguntas de pesquisa frequentemente investigam se X tem um efeito causal em Y em casos específicos. Por exemplo, se houvesse uma crise econômica no Brasil hoje, Lula sofreria impeachment? Em termos contrafactuais, a questão é se, ao intervir exogenamente no valor de X , o valor de Y mudaria. Ou seja, qual seria o tipo causal do Brasil sob Lula III? Se não haveria impeachment com ou sem crise, e considerando impeachment como 1 e não-impeachment como 0, então seria um tipo crônico, pois o impedimento não seria observado com e sem crise econômica. Em outras palavras, poderíamos estar interessados na probabilidade de ser crônico. Ou talvez a pergunta de pesquisa seria em torno da probabilidade do país ser benéfico, isto é, o impeachment ocorreria com crise econômica, mas não em sua ausência. Neste modelo, o estimando corresponde à proporção de casos do tipo crônico em uma população definida pelo conjunto de casos comparáveis.

Esse tipo de query nos ajuda a entender as implicações de mudanças específicas em variáveis causais. O modelo de queries causais aqui apresentado permite responder a esse tipo de pesquisa,

tipicamente qualitativas, de maneira quantitativamente precisa, a partir de estudo de caso.

6.2.2 Atribuição Causal ao Nível do Caso

Além de investigar se X tem um efeito causal, também é importante determinar se X de fato causou Y em casos específicos. Por exemplo, a crise econômica causou o impeachment da Dilma em 2016? Em termos contrafactuais, a questão é se, dado os valores que X e Y assumiram, o valor de Y seria diferente se o valor de X fosse diferente. Este tipo de análise é crucial para entender a relação direta entre causas e efeitos em contextos específicos.

6.2.3 Caminhos Causais

Em casos onde estabelecemos que X causou Y , é relevante investigar se isso ocorreu via um mediador M . Em notação de resultados potenciais, perguntamos se $Y(X = x, M = M(X = 1))$ é maior do que $Y(X = x, M = M(X = 0))$. Este tipo de query nos ajuda a mapear as vias por meio das quais os efeitos causais se manifestam.

6.3 Comparando as Abordagens

As duas metodologias são duas implementações concretas da mesma lógica de comparação Bayesiana de explicações rivais defendida nas seções anteriores. Os trabalhos de Fairfield e Charman têm como objetivo formalizar o rastreamento de processos, com ênfase na operacionalização das verossimilhanças via decibéis e na disciplina da formulação explícita de hipóteses rivais a comparar. O modelo de *queries* causais de Humphreys e Jacobs é mais genérico, podendo ser aplicado a uma variedade de desenhos qualitativos, incluindo rastreamento de processo, e admite hipóteses não estritamente excludentes (complementares ou parciais). Por outro lado, ao não incorporar a heurística dos decibéis, perde uma régua útil que Fairfield e Charman desenvolvem para calibrar o peso das evidências.

Os DAGs com variáveis não-observadas que frequentemente aparecem no modelo de Humphreys e Jacobs registram que a credibilidade de uma inferência pode ser limitada — exatamente como em qualquer estudo qualitativo. Conforme defendido em seção anterior, contudo, essa limitação não é *eliminada* por nenhuma das duas abordagens, mas *reformulada*: a variável omitida deixa

de ser uma incógnita externa ao desenho e passa a ser uma das hipóteses rivais a ser comparada explicitamente, sob o critério de inferência à melhor explicação. As duas implementações divergem em vocabulário e em ergonomia, mas convergem na arquitetura comum — enumerar rivais, atribuir verossimilhanças, comparar *posteriors*. A questão prática para a pesquisadora é qual aparato facilita melhor seu objeto particular, não qual delas “resolve” um problema que nenhum aparato resolve no sentido formal quantitativo.

Como são metodologias novas, aperfeiçoamentos e mesmo a mistura de ambas podem vir a ser desenvolvimentos possíveis. Por hora, importa salientar que ambas são promissoras e o método de process tracing Bayesiano já está sendo aplicado (Fairfield and Charman 2025; Rabbia 2023), inclusive com alunos que viram o conteúdo em aula e já disseram que estão usando em seus trabalhos (ainda não publicados). Contudo, é esperado que seja necessário treinamento mais longo e extenso, como os próprios autores reconhecem em seus trabalhos.

7 Limitações práticas e trade-offs

A operacionalização Bayesiana da comparação de explicações rivais não é gratuita, e a apresentação anterior pode subestimar custos práticos. Esta seção elenca seis limitações que merecem reconhecimento explícito antes de qualquer recomendação de adoção.

Elicitação de priors. A atribuição de probabilidades *a priori* a hipóteses concorrentes é, em pesquisas qualitativas, frequentemente subdeterminada. Há uma literatura técnica desenvolvida sobre elicitación formal (O’Hagan 2019; O’Hagan et al. 2006), mas sua aplicação fora de contextos com expertise quantificável (engenharia, epidemiologia) tende a ser custosa e nem sempre informativa. A recomendação prática mais segura — uso de priors não-informativas seguido de análise de robustez sob priors alternativas — incorre em custo cognitivo real para pesquisadoras sem treinamento Bayesiano prévio.

Verossimilhanças e replicabilidade entre pesquisadoras. A construção da verossimilhança $P(E_k | H_i)$ depende de julgamentos qualitativos sobre o quão esperada cada evidência seria sob cada hipótese — julgamentos cuja calibração pode variar entre pesquisadoras experientes. A heurística de decibéis proposta por Fairfield and Charman (2022) ajuda na disciplina, mas não elimina a

discricionariedade. Análise de robustez (variar verossimilhanças e exibir como o *ranking* posterior se altera) é o paliativo recomendado, mas amplia o trabalho.

Risco de “teatro Bayesiano”. O formalismo da regra de Bayes pode ser empregado decorativamente — números atribuídos sem critério, comparações apresentadas como precisas quando são fundamentalmente especulativas. O paliativo é o oposto da formalização superficial: prioris transparentes, verossimilhanças justificadas com referência à literatura prévia, análise de robustez explícita, e disposição para tratar a comparação como diagnóstico iterativo, não como resultado fechado.

Curva de aprendizado e treinamento de pesquisadoras. Programas de pós-graduação em ciência política e relações internacionais no Brasil, em geral, não oferecem treinamento Bayesiano sistemático. A operacionalização aqui defendida pressupõe familiaridade conceitual com o teorema de Bayes, com a leitura de verossimilhanças como razões de plausibilidade, e com análise de sensibilidade — competências que exigem investimento curricular específico.

Quando não usar. A comparação Bayesiana de rivais é uma tecnologia de credibilidade para perguntas causais explicativas em n pequeno. Não é a ferramenta apropriada para: (i) estudos descritivos cujo objetivo é caracterizar fenômenos, não explicá-los; (ii) perguntas em que o conjunto de rivais não é finito ou claramente delimitado pela literatura existente; (iii) estudos cujo desafio principal é interpretativo (qual significado os atores atribuem ao evento) e não causal-explicativo.

Comparação com process tracing não-Bayesiano. Process tracing na tradição Bennett-Checkel-Beach-Pedersen (Bennett and Checkel 2015; Beach and Pedersen 2019) dispensa a quantificação Bayesiana e opera com tipologia de testes (*hoop tests*, *smoking guns*, *doubly decisive*) cuja calibração é qualitativa. O ganho da abordagem Bayesiana é a explicitação dos pesos relativos das evidências e a possibilidade de análise de robustez quantitativa; o custo é a sobrecarga formal e o risco de teatro. Estudos com poucas evidências bem caracterizadas e com ampla familiaridade da pesquisadora com a literatura podem encontrar no process tracing tradicional o instrumento adequado, sem necessidade da maquinaria Bayesiana adicional.

8 Uma ilustração: o impeachment de 2016 sob comparação Bayesiana de explicações rivais

Para tornar concreta a operacionalização proposta, aplicamos a comparação Bayesiana a uma pergunta com debate ativo na literatura politológica brasileira: por que Dilma Rousseff sofreu impeachment em 2016?²

8.1 Hipóteses rivais

Selecionamos três explicações que organizam vertentes do debate:

- H_1 — *Crise econômica e perda de coalizão*: a recessão de 2014–2016 (PIB negativo, desemprego em alta, inflação ascendente) destruiu a popularidade do governo e precipitou o colapso da coalizão parlamentar;
- H_2 — *Desgaste por escândalos e Lava Jato*: a Operação Lava Jato e a sucessão de delações premiadas envolvendo o PT minaram a base política e legitimaram simbolicamente o impeachment;
- H_3 — *Mobilização das elites político-econômicas*: setores das elites econômicas e do Congresso utilizaram as “pedaladas fiscais” como pretexto institucional para destituir um governo cujas políticas distributivas se opunham a seus interesses.

Em sua versão substantiva, as hipóteses não são logicamente exclusivas — fatores econômicos, escândalos e mobilização de elites podem coexistir como contribuintes parciais. Para fins desta ilustração, tratamos cada uma como pretensão de fator dominante e estipulamos $\sum_i P(H_i) = 1$.

8.2 Evidências

Três evidências centrais, observáveis publicamente:

- E_1 — Queda da aprovação de Dilma de 47% (Datafolha, fev/2014) para 8% (Datafolha,

²O exemplo é deliberadamente esquemático e ilustrativo. As hipóteses correspondem a interpretações sustentadas por vertentes distintas do debate brasileiro sobre a crise de 2016, mas não pretendemos esgotar a literatura nem atribuir cada hipótese a autores específicos; os valores numéricos atribuídos às verossimilhanças refletem julgamentos plausíveis à luz do debate público disponível, mas servem ao propósito didático de exibir a maquinaria do método. Uma aplicação substantiva exigiria elicitação cuidadosa caso a caso, eventualmente com expertise multidisciplinar.

ago/2015);

- E_2 — Concentração temporal das delações premiadas e operações de busca e apreensão da Lava Jato no período jul/2015–mar/2016;
- E_3 — Conteúdo dos discursos parlamentares na votação aberta do impeachment (abril/2016), dominado por temas de família, Deus e patriotismo, e não por argumentos econômicos ou de corrupção específica.

8.3 Verossimilhanças

Atribuímos verossimilhanças $P(E_k|H_i)$ refletindo o quão esperada cada evidência é sob cada hipótese:

Evidência	H_1 (econômica)	H_2 (Lava Jato)	H_3 (elites)
E_1 (queda popularidade)	0,9	0,6	0,3
E_2 (timing das delações)	0,2	0,8	0,4
E_3 (conteúdo dos discursos)	0,3	0,2	0,7

Em decibéis, comparações pareadas para cada evidência:

- E_1 favorece H_1 sobre H_3 em $10 \log_{10}(0,9/0,3) \approx +4,8$ dB;
- E_2 favorece H_2 sobre H_1 em $10 \log_{10}(0,8/0,2) \approx +6,0$ dB;
- E_3 favorece H_3 sobre H_2 em $10 \log_{10}(0,7/0,2) \approx +5,4$ dB.

Cada evidência, isoladamente, favorece uma hipótese diferente — situação realista em estudos qualitativos de n pequeno com explicações causais multifacetadas.

8.4 Posteriors

Sob prioris uniformes ($P(H_i) = 1/3$) e independência condicional das evidências dadas as hipóteses, as probabilidades posteriores normalizadas são:

$$P(H_1 | E_1, E_2, E_3) \approx 0,23 \quad P(H_2 | E_1, E_2, E_3) \approx 0,41 \quad P(H_3 | E_1, E_2, E_3) \approx 0,36$$

A hipótese mais bem sustentada pelo conjunto de evidências é H_2 (Lava Jato), seguida de perto por H_3 (elites); H_1 (econômica pura) é a menos sustentada. A força da preferência por H_2 é, contudo, modesta: a razão de odds H_2/H_3 rende apenas $\approx +0,6$ dB, distante do limiar que Fairfield e Charman associam a evidência saliente.

8.5 Sensibilidade e enumeração

A análise é frágil em duas direções. Primeiro, alterar uma única verossimilhança realinha o *ranking*: se julgarmos $P(E_2 \mid H_3) = 0,6$ — aceitando que setores de elite podem ter mobilizado e aproveitado estrategicamente o cronograma da Lava Jato —, $P(H_3 \mid E)$ sobe para aproximadamente 0,50 e ultrapassa H_2 . Segundo, e mais importante para o argumento desta nota, a análise depende criticamente do conjunto de rivais considerado. Uma quarta hipótese plausível — H_4 , *erro estratégico do PT na gestão da coalizão* (escolha de Temer como vice; isolamento parlamentar progressivo a partir de 2014) — não foi incluída. Sua inclusão modificaria a comparação de modo qualitativo: H_4 é particularmente compatível com E_1 (queda da popularidade reflete percepção de governo desgovernado) e parcialmente com E_3 (discursos focados em valores são compatíveis com captura de uma agenda comportamental pela oposição em vácuo programático). Outras candidatas — instabilidade institucional pós-2013, hostilidade crescente de setores da imprensa, reorientação ideológica do eleitorado de classe média — são igualmente plausíveis.

8.6 Discussão

O exercício ilustra três pontos centrais. Primeiro, a comparação Bayesiana de rivais produz inferência operacional mesmo com $n = 1$: a pergunta “por que esse caso?” é respondida em termos de probabilidade posterior diante de um conjunto explícito de explicações concorrentes. Segundo, a sensibilidade do *ranking* à atribuição numérica das verossimilhanças é uma virtude, não um defeito: ela torna explícitos os pontos de discordância entre pesquisadores e permite *análise de robustez* via *prioris* e verossimilhanças alternativas. Terceiro, e crucial para o argumento desta nota, a objeção mais informativa contra esta análise não é “e se houver uma variável U não-observada confundindo a relação?”: postulada abstratamente, qualquer terceira variável é livremente conjecturável e não interage com nenhum padrão observado em particular. A objeção informativa é “qual rival adicional

não foi considerado, e como sua inclusão alteraria a comparação?” — pergunta que tem resposta concreta (por exemplo, H_4 acima), que muda a comparação de modo verificável e que disciplina a discussão entre pesquisadores. É essa migração no critério de credibilidade — do controle de variáveis omitidas via desenho para a robustez da enumeração de rivais sob comparação Bayesiana — que distingue a infraestrutura de credibilidade do quali de n pequeno daquela da revolução da credibilidade.

9 Transportabilidade, Generalização ou Validade Externa

A preocupação com identificação causal, destacada pela revolução da credibilidade, implicou uma ênfase na validade interna dos estudos. Adotamos aqui a definição operativa do paradigma Pearl/Rubin: um estudo tem validade interna quando seu desenho satisfaz as suposições que tornam o estimando recuperável a partir da população — uma propriedade do desenho, logicamente independente do tamanho da amostra observada. Convivem na literatura qualitativa traduções alternativas (notadamente a tradição Campbell-McDermott, que vincula validade interna à adequação amostral); marcamos sua existência sem mobilizá-la como definição operativa. A validade externa, por sua vez, refere-se à transportabilidade dos efeitos estimados para populações não estudadas (Findley, Kikuta, and Denly 2021; Muller 2015).

Aplicado esse vocabulário, a validade interna de um estudo qualitativo de n pequeno é avaliada via a infraestrutura de credibilidade própria — comparação Bayesiana de explicações rivais sob inferência à melhor explicação —, não via tecnologia de desenho da revolução da credibilidade. Não há, portanto, característica intrínseca do quali ou do quanti que justifique pré-julgamento sobre validade interna: cada estudo é avaliado pelas tecnologias de credibilidade compatíveis com seu desenho próprio.

Importa registrar uma consequência específica desse vocabulário, frequentemente obscurecida na literatura qualitativa. Há uma tese disseminada em tradições centrais da metodologia qualitativa contemporânea (Sposito, Gabriel, and Artioli 2022) segundo a qual estudos de caso aprofundados possuiriam validade interna intrínseca, conferida pela densidade da reconstrução do caso. Sob o vocabulário aqui adotado, a profundidade descritiva é condição necessária para gerar a evidência sobre a qual a comparação Bayesiana opera, mas não a substitui. Validade interna no quali pequeno- n é

propriedade do procedimento de comparação de explicações rivais — exaustividade da enumeração, qualidade das verossimilhanças, magnitude dos *posterior odds* — e não do desenho per se, nem da densidade descritiva do material analisado.

Similarmente, as duas metodologias são igualmente limitadas (a princípio) em sua capacidade de possuírem validade externa. E essas duas conclusões seguem do fato de que não há relação entre validade interna e externa e tamanho amostral, se a pesquisa é em profundidade ou não, ou quaisquer das possíveis distinções empregadas para diferenciar métodos qualitativo de quantitativo.

Como discutido anteriormente, a inferência causal depende inicialmente da satisfação das condições para identificação causal. Uma vez resolvida essa questão, a inferência estatística pode ser feita por meio de métodos bayesianos apropriados para estudos com pequeno n . Contudo, isso garante apenas a validade interna do estudo, ou seja, não permite, por si só, generalizar os resultados para outros contextos ou populações, o que caracteriza a validade externa.

Nesse sentido, a suposta incapacidade de generalização devido ao pequeno número de casos analisados não tem fundamento sólido. Tanto estudos quantitativos quanto qualitativos geralmente compartilham as mesmas limitações quanto à generalização, refletidas na ausência de garantias explícitas sobre sua validade externa.

A distinção entre validade interna e externa foi introduzida por Campbell (1957) no contexto de estudos experimentais. Na definição original, validade interna referia-se à capacidade de um experimento detectar o efeito causal de interesse na amostra estudada. Atualmente, consideramos que um estudo (não apenas experimental) tem validade interna quando seu desenho, execução (incluindo coleta de dados) e análise permitem responder adequadamente às perguntas de pesquisa para a amostra analisada (McDermott (2011)).

A validade externa, por outro lado, diz respeito a transportar os efeitos estimados de uma população a outra (Pearl and Bareinboim 2011, 2022). No arcabouço de resultados potenciais, a validade externa pode ser definida do seguinte modo. Seja D_i uma variável binária que indica se uma unidade está na amostra ($D_i = 0$) ou na população de interesse ($D_i = 1$). Dizemos que existe validade externa se $\mathbb{E}[Y_i(1) - Y_i(0)|D_i = 0] = \mathbb{E}[Y_i(1) - Y_i(0)|D_i = 1]$. Em palavras, a diferença média nos resultados potenciais do tratamento e controle na população de interesse é igual ao da população de onde foi retirada a amostra. Com a utilização de DAGs, a literatura tem mostrado

que o essencial é especificar quais variáveis da população alvo podem modificar o efeito causal em relação à população estudada.

No simpósio da QMMR de 2023 sobre o livro de Fairfield e Charman (Fairfield and Charman 2022), Jacobs (Jacobs 2023) e Fairfield e Charman (Fairfield and Charman 2023) discutem a questão da transportabilidade (sob o nome de generalização) a partir de um caso presente no livro de Fairfield and Charman (2022): qual a causal da mobilização democrática no sudeste asiático autoritário? Três hipóteses são consideradas: 1. elites comunais autônomas promovendo mobilização; 2. declínio econômico como o fator central e 3. eleições fraudadas. Ao analisar evidência de Filipinas e Vietnã, concluem que a hipótese mais provável é a de elites comunais. Como Jacobs observa, dada a condição de escopo, a plausibilidade dessa explicação se aplica igualmente a todos os países autoritários do sudeste asiático, como Tailândia e Malásia autocráticas.

A resposta de (Fairfield and Charman 2023), de que podemos contrapor outra hipótese com outra condição de escopo, parece-nos insuficiente. No exemplo dado pelos autores, se a hipótese rival for “The communal-elites causal logic operates in the Philippines and Vietnam, whereas economic decline instead sparks democratic mobilization elsewhere in Southeast Asia”, evidência da Filipinas apenas será incapaz de informar ou diferenciar entre as hipóteses.

A recomendação de Fairfield e Charman sobre generalização — redefinir condições de escopo ao se contrapor novas hipóteses — tem força didática: força a pesquisadora a explicitar quando seu argumento se aplica e quando não. Mas, lida na chave operacional desenvolvida nesta nota, ela tem uma consequência menos confortável: a redefinição de escopo, quando não acompanhada de teorização independente sobre o que distingue o sub-conjunto novo, esvazia a finitude do conjunto de rivais. Suponha que, após a análise de Filipinas e Vietnã, evidências adicionais coletadas na Malásia reforcem a hipótese original. Pela recomendação tomada estritamente, é possível imediatamente formular uma hipótese ad hoc segundo a qual a explicação valeria nesses três casos, enquanto outro fator (declínio econômico, por exemplo) explicaria países ainda não examinados. A finitude do conjunto de rivais — que é, conforme estabelecido em seção anterior, parte do critério de credibilidade da comparação — fica subvertida.

A consequência prática é que o escopo precisa ser tratado como objeto de teorização explícita, não como variável de ajuste. A perspectiva aqui defendida sugere a necessidade de explicitar os

mecanismos causais que delimitam o escopo de aplicação, fornecendo critérios claros e testáveis para avaliar a validade da generalização.

No exemplo acima, a pesquisa qualitativa que pretende generalizar para além dos casos estudados deve teorizar sobre que mecanismo faria Filipinas e Vietnã serem diferentes do restante do sudeste asiático. Em outras palavras, não é uma boa prática simplesmente afirmar hipóteses distintas modificando o escopo, mas é necessário teorizar o que determina que um escopo seja válido ou não. Retornando ao exemplo do trabalho de Skocpol, suas condições de escopo não são apenas os casos de China, Rússia e França, mas o caso de países agrários, não-colonizados recentemente e com estados proto-burocráticos enfrentando adversários economicamente desenvolvidos. Isso significa que, se formos transportar essa explicação para, digamos, Cuba, teremos que avaliar em que medida um estado parcialmente colonizado e pouco burocrático terá condições diferentes e explicações potencialmente diferentes.

Como esse exemplo mostra, a generalização é difícil de ser realizada e as soluções propostas na literatura estão longe de serem ponto pacífico. Contudo, tampouco é algo resolvido na abordagem influenciada pela revolução da credibilidade. Se algo, por hora parece mais fácil endereçar essa questão na pesquisa qualitativa do que na quantitativa, como mostramos acima. Mas é a prática aplicada que irá dizer em que medida cada abordagem irá lidar com esse problema.

10 Considerações Finais

Após o livro de KKV, consolidou-se a percepção (falsa) de que métodos qualitativos seriam mais limitados em sua capacidade de generalização, embora superiores em sua validade interna. Essa percepção, baseada na adoção da perspectiva então vigente de modelos de regressão quantitativos, dependia da ideia errônea de que inferência causal e estatística eram a mesma coisa.

A revolução da credibilidade trouxe uma nova perspectiva, segundo a qual a identificação causal — entendida como condição do desenho de pesquisa relativa à população — é logicamente distinta da inferência estatística — problema da amostra. Como resultado, mostramos que não há nenhuma característica intrínseca à pesquisa quali ou quanti que justifique diferenças quanto à validade interna ou externa: cada uma dispõe de uma infraestrutura de credibilidade própria — tecnologias de

desenho na quanti, comparação Bayesiana de rivais sob inferência à melhor explicação na quali de n pequeno.

Vale punctuar a consequência mais direta dessa reorganização. A tese, ainda corrente na literatura metodológica qualitativa, de que o estudo de caso aprofundado possui validade interna por construção — derivada da profundidade analítica, e independentemente de comparação com explicações rivais — opera num enquadramento que antecede a sistematização da separação entre identificação causal e inferência estatística. Substituída a propriedade intrínseca pelo procedimento de comparação Bayesiana sob critério de inferência à melhor explicação, a credibilidade do estudo qualitativo passa a depender da exaustividade do conjunto de rivais considerados e da qualidade das verossimilhanças que distinguem entre eles, mais do que da densidade descritiva isoladamente.

A separação organiza também a discussão de seleção de casos. Selecionar pelo valor da variável dependente pode induzir viés de colisor (problema estrutural do desenho); selecionar de modo não-aleatório limita o que se conclui sobre populações alheias aos casos selecionados (problema de validade externa); tamanho pequeno de amostra afeta a precisão da inferência estatística (problema separado). A literatura qualitativa pós-KKV — brasileira inclusive (Sposito, Gabriel, and Artioli 2022) — herdou a fusão dos três sob “lógica única de inferência” e a reproduz em tipologias de “lógicas próprias de seleção”. Decompostos, os três problemas têm respostas distintas: o primeiro é tratado por desenho que evite condicionar em Y , não por enumeração de rivais — a comparação Bayesiana desenvolvida nesta nota se aplica ao problema do U inventável abstratamente, não ao colisor estrutural do desenho; o segundo é resolvido, quando o é, pela teorização explícita do escopo; o terceiro é absorvido pela inferência Bayesiana. Estudos quantitativos modernos com seleção radicalmente não-aleatória — Card and Krueger (1994) com dois estados, Abadie, Diamond, and Hainmueller (2015) com uma única unidade tratada — ilustram que a lógica causal é a mesma em qualquer regime de N e independentemente de aleatoriedade na seleção: a pergunta sobre seleção de casos passa a ser “as suposições de identificação são defensáveis para os casos escolhidos?” no lugar de “a amostra representa o universo?”.

Tomada em conjunto, a reorganização desloca o eixo metodológico central do debate pós-KKV: “ n grande vs n pequeno” é mal-enquadrado como critério de inferência causal. Identificação e inferência podem operar em qualquer regime de n , sob critérios de credibilidade próprios — tecnologias

de desenho com múltiplas observações na quanti, comparação Bayesiana de rivais em pequeno- n qualitativo. A comparação metodológica relevante é entre essas infraestruturas de credibilidade, não entre tamanhos de amostra.

Desfeita essa confusão, mostramos que a inferência Bayesiana oferece soluções robustas para a inferência em amostras pequenas, equiparando o rigor das pesquisas qualitativas ao das quantitativas. As ilustrações metodológicas, como o *process tracing* Bayesiano e as *queries* causais, exemplificam como essas novas abordagens podem ser aplicadas na prática. Esses métodos permitem uma análise mais detalhada e precisa, reforçando a validade dos estudos qualitativos.

Por fim, abordamos como a literatura baseada na ideia de transportabilidade pode permitir que a pesquisa qualitativa supere suas limitações quanto à validade externa.

Assim, o trabalho contribui para tornar mais claras as dificuldades e caminhos da pesquisa qualitativa baseada em casos, desfazendo qualquer pretensão de superioridade intrínseca da pesquisa quantitativa causal. Esperamos que este estudo inspire uma reavaliação das abordagens metodológicas nas ciências sociais, promovendo um debate mais equilibrado e integrador.

11 References

- Abadie, Alberto, Alexis Diamond, and Jens Hainmueller. 2015. "Comparative Politics and the Synthetic Control Method." *American Journal of Political Science* 59 (2). Wiley Online Library: 495–510.
- Albert, Isabelle, Sophie Donnet, Chantal Guihenneuc-Jouyaux, Samantha Low-Choy, Kerrie Mengersen, and Judith Rousseau. 2012. "Combining Expert Opinions in Prior Elicitation."
- Angrist, Joshua D., and Alan B. Krueger. 1991. "Does Compulsory School Attendance Affect Schooling and Earnings?" *The Quarterly Journal of Economics* 106 (4). MIT Press: 979–1014.
- Angrist, Joshua D., and Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton university press.
- . 2010. "The Credibility Revolution in Empirical Economics: How Better Research Design Is Taking the Con Out of Econometrics." *Journal of Economic Perspectives* 24 (2). American Economic Association: 3–30.
- Beach, Derek, and Rasmus Brun Pedersen. 2019. *Process-Tracing Methods: Foundations and Guidelines*. 2nd ed. Ann Arbor, MI: University of Michigan Press.
- Bennett, Andrew, and Jeffrey T. Checkel. 2015. *Process Tracing*. Cambridge University Press.
- Bouchat, Sirus. 2023. "Social Inquiry and Bayesian Inference: An "Objective" Vision for Mixed Method Research?" November. Zenodo. doi:10.5281/ZENODO.8326432.
- Brady, Henry E, and David Collier. 2010. *Rethinking Social Inquiry: Diverse Tools, Shared Standards*. Rowman & Littlefield Publishers.
- Campbell, Donald T. 1957. "Factors Relevant to the Validity of Experiments in Social Settings." *Psychological Bulletin* 54 (4).
- Card, David. 2022. "Design-Based Research in Empirical Microeconomics." *American Economic Review* 112 (6). American Economic Association 2014 Broadway, Suite 305, Nashville, TN 37203: 1773–81.
- Card, David, and Alan B. Krueger. 1994. "Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania." *The American Economic Review* 84 (4): 772–93.
- Collier, David. 2011. "Understanding Process Tracing." *PS: Political Science & Politics* 44 (4). Cambridge University Press: 823–30.
- da Cunha Rezende, Flávio. 2011. "Razões Emergentes Para a Validade Dos Estudos de Caso Na Ciência Política Comparada." *Revista Brasileira de Ciência Política*, no. 6. <https://www.scielo.br/j/rbcpol/a/KFWXKW9VQNmQTt7BZpsV4rx/>.
- . 2017. "Transformações Na Cientificidade e o Ajuste Inferencial Na Ciência Política: Argumento e Evidências Na Produção de Alto Fator de Impacto." *Revista de Sociologia e Política* 25. SciELO Brasil: 103–38.
- . 2019. "As lógicas Da Inferência Causal Na Ciência Política: Argumento e Evidências." *Revista Política Hoje* 28 (2). <https://periodicos.ufpe.br/revistas/politica hoje/article/view/248309>.
- Fairfield, Tasha, and Andrew Charman. 2019. "A Dialogue with the Data: The Bayesian Foundations of Iterative Research in Qualitative Social Science." *Perspectives on Politics* 17 (1). Cambridge University Press: 154–67.
- . 2022. *Social Inquiry and Bayesian Inference*.
- . 2023. "Bayesian Reflections," November. Zenodo. doi:10.5281/ZENODO.8326443.
- . 2025. "Bayesian Reasoning for Qualitative Replication Analysis: Examples from Climate Politics." *Political Science Research and Methods*. Cambridge University Press, 1–16.

- Fairfield, Tasha, and Andrew E. Charman. 2017. "Explicit Bayesian Analysis for Process Tracing: Guidelines, Opportunities, and Caveats." *Political Analysis* 25 (3). Cambridge University Press: 363–80.
- Figueiredo Filho, Dalson Britto, Antônio Fernandes, Lucas Borba, and Thaís Helena Aguiar. 2021. "Metodologias de Pesquisa Em Ciência Política: Uma Breve Introdução." *BIB - Revista Brasileira de Informação Bibliográfica Em Ciências Sociais*, no. 94. <https://bibanpocs.emnuvens.com.br/revista/article/view/175>.
- Findley, Michael G., Kyosuke Kikuta, and Michael Denly. 2021. "External Validity." *Annual Review of Political Science* 24 (1): 365–93. doi:10.1146/annurev-polisci-041719-102556.
- Forozish, Ali Omar. 2024. "How the Credibility Revolution Created a Paradigm Shift." *Available at SSRN 4744474*.
- Gelman, Andrew. 2009. "Bayes, Jeffreys, Prior Distributions and the Philosophy of Statistics." *Statistical Science* 24 (2). JSTOR: 176–78. <https://www.jstor.org/stable/25681293>.
- Gelman, Andrew, Daniel Simpson, and Michael Betancourt. 2017. "The Prior Can Often Only Be Understood in the Context of the Likelihood." *Entropy* 19 (10). MDPI: 555.
- Glied, Sherry. 2021. "The Credibility Revolution in Economics and How It Has Changed Health Policy." In *JAMA Health Forum*, 2:e214335–35. American Medical Association.
- Goldsmith-Pinkham, Paul. 2024. "Tracking the Credibility Revolution Across Fields." arXiv. <https://arxiv.org/abs/2405.20604>.
- Grimmer, Justin. 2015. "We Are All Social Scientists Now: How Big Data, Machine Learning, and Causal Inference Work Together." *PS: Political Science & Politics* 48 (1). Cambridge University Press: 80–83.
- Humphreys, Macartan, and Alan M. Jacobs. 2015. "Mixing Methods: A Bayesian Approach." *American Political Science Review* 109 (4). Cambridge University Press: 653–73.
- . 2023. "Integrated Inferences." *Null*. doi:10.1017/9781316718636.
- Imbens, Guido W. 2020. "Potential Outcome and Directed Acyclic Graph Approaches to Causality: Relevance for Empirical Practice in Economics." *Journal of Economic Literature* 58 (4): 1129–79. doi:10.1257/jel.20191597.
- Jacobs, Alan M. 2023. "Leaning in to Analytic Explicitness," November. Zenodo. doi:10.5281/ZENODO.8326449
- Kass, Robert E., and Larry Wasserman. 1996. "The Selection of Prior Distributions by Formal Rules." *Journal of the American Statistical Association* 91 (435): 1343–70. doi:10.1080/01621459.1996.10477003.
- Keele, Luke. 2015a. "The Discipline of Identification." *PS: Political Science & Politics* 48 (1). Cambridge University Press: 102–6.
- . 2015b. "The Statistics of Causal Inference: A View from Political Methodology." *Political Analysis* 23 (3). Cambridge University Press: 313–35.
- King, Gary, Robert O. Keohane, and Sidney Verba. 1994. *Designing Social Inquiry: Scientific Inference in Qualitative Research*. Princeton University Press. doi:10.1515/9781400821211.
- Koivu, Kendra L., and Erin Kimball Damman. 2015. "Qualitative Variations: The Sources of Divergent Qualitative Methodological Approaches." *Quality & Quantity* 49. Springer: 2617–32.
- Leamer, Edward E. 1983. "Let's Take the Con Out of Econometrics." *The American Economic Review* 73 (1). JSTOR: 31–43. <https://www.jstor.org/stable/1803924>.
- Leite, Rodrigo, and Gustavo de Andrade Rocha. 2019. "Desenho de Pesquisa, Inferência e Causalidade: Caminhos Entre a Abordagem Qualitativa e Quantitativa." *Revista Eletrônica de Ciência*

- Política* 10 (1): 107–19. <https://revistas.ufpr.br/politica/article/view/61004>.
- Libman, Alexander. 2023. “Credibility Revolution and the Future of Russian Studies.” *Post-Soviet Affairs* 39 (1-2): 60–69. doi:10.1080/1060586X.2022.2148446.
- Lipton, Peter. 2004. *Inference to the Best Explanation*. 2nd ed. London: Routledge.
- Lundberg, Ian, Rebecca Johnson, and Brandon M. Stewart. 2021. “What Is Your Estimand? Defining the Target Quantity Connects Statistical Evidence to Theory.” *American Sociological Review* 86 (3): 532–65. doi:10.1177/00031224211004187.
- Mackie, J. L. 1965. “Causes and Conditions.” *American Philosophical Quarterly* 2 (4). University of Illinois Press: 245–64.
- McDermott, Rose. 2011. “Internal and External Validity.” *Cambridge Handbook of Experimental Political Science* 27.
- Mesquita, Rafael. 2017. “Desenho de Pesquisa, Inferência e Causalidade Em Ciência Política e Relações Internacionais: Uma Introdução Didática.” *Revista Política Hoje* 26 (2). <https://periodicos.ufpe.br/revistas/politica/hoje/article/view/234402>.
- Morgan, Stephen L., and Christopher Winship. 2015. *Counterfactuals and Causal Inference: Methods and Principles for Social Research*. 2nd ed. Cambridge: Cambridge University Press.
- Muller, Seán M. 2015. “Causal Interaction and External Validity: Obstacles to the Policy Relevance of Randomized Evaluations.” *The World Bank Economic Review* 29 (suppl 1): S217–25. doi:10.1093/wber/lhv027.
- O’Hagan, Anthony. 1998. “Eliciting Expert Beliefs in Substantial Practical Applications.” *Journal of the Royal Statistical Society Series D: The Statistician* 47 (1). Oxford University Press: 21–35.
- . 2010. *Kendall’s Advanced Theory of Statistic 2B*. John Wiley & Sons.
- . 2019. “Expert Knowledge Elicitation: Subjective but Scientific.” *The American Statistician* 73 (supl): 69–81. doi:10.1080/00031305.2018.1518265.
- O’Hagan, Anthony, Caitlin E. Buck, Alireza Daneshkhah, J. Richard Eiser, Paul H. Garthwaite, David J. Jenkinson, Jeremy E. Oakley, and Tim Rakow. 2006. “Uncertain Judgements: Eliciting Experts’ Probabilities.” John Wiley & Sons.
- Paula, Julio Cesar Guimarães de. 2018. “Em Busca Da Inferência válida: Métodos e Testes de Hipóteses Nos Estudos Legislativos Brasileiros.” *Revista Brasileira de Ciência Política*, no. 26. <https://www.scielo.br/j/rbcpol/a/pG4v5GHwd3rJxsLThVckNrv/>.
- Pearl, Judea, and Elias Bareinboim. 2011. “Transportability of Causal and Statistical Relations: A Formal Approach.” In *Proceedings of the AAAI Conference on Artificial Intelligence*, 25:247–54.
- . 2022. “External Validity: From Do -Calculus to Transportability Across Populations.” In *Probabilistic and Causal Inference*, edited by Hector Geffner, Rina Dechter, and Joseph Y. Halpern, 1st ed., 451–82. New York, NY, USA: ACM. doi:10.1145/3501714.3501741.
- Perissinotto, Renato. 2024. “QCA e Process Tracing: Conectando Ciência Política e História.” *Revista Brasileira de Ciências Sociais* 39. <https://www.scielo.br/j/rbcsoc/a/KYXyZtgMQxXKmzLHshMfrRD/>.
- Rabbia, Martin. 2023. “Why Did Argentina and Uruguay Decide to Pursue a Carbon Tax? Fiscal Reforms and Explicit Carbon Prices.” *Review of Policy Research* 40 (2). Wiley Online Library: 230–59.
- Ragin, Charles C. 2014. *The Comparative Method: Moving Beyond Qualitative and Quantitative Strategies*. Univ of California Press.

- Rihoux, Benoît, and Charles C. Ragin. 2009. *Configurational Comparative Methods: Qualitative Comparative Analysis (QCA) and Related Techniques*. Vol. 51. Sage.
- Rubin, Donald B. 1974. "Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies." *Journal of Educational Psychology* 66 (5). American Psychological Association: 688.
- Samii, Cyrus. 2016. "Causal Empiricism in Quantitative Research." *The Journal of Politics* 78 (3): 941–55. doi:10.1086/686690.
- Seawright, Jason. 2018. "Beyond Mill: Why Cross-Case Qualitative Causal Inference Is Weak, and Why We Should Still Compare," March. Zenodo. doi:10.5281/ZENODO.2562153.
- Sekhon, Jasjeet S. 2004. "Quality Meets Quantity: Case Studies, Conditional Probability, and Counterfactuals." *Perspectives on Politics* 2 (02). doi:10.1017/S1537592704040150.
- Silva, Glauco Peres da. 2023. *Desenho de Pesquisa*. Edição revisada. Coleção Metodologias de Pesquisa. Brasília: ENAP. [https://repositorio.enap.gov.br/bitstream/1/3330/4/Livro_desenho_de_pesquisa%20\(2\).pdf](https://repositorio.enap.gov.br/bitstream/1/3330/4/Livro_desenho_de_pesquisa%20(2).pdf).
- Skocpol, Theda. 1979. *States and Social Revolutions: A Comparative Analysis of France, Russia and China*. Cambridge University Press.
- Slater, Dan, and Daniel Ziblatt. 2013. "The Enduring Indispensability of the Controlled Comparison." *Comparative Political Studies* 46 (10). SAGE Publications Sage CA: Los Angeles, CA: 1301–27.
- Spirling, Arthur, and Brandon M. Stewart. 2025. "What Good Is a Regression? Inference to the Best Explanation and the Practice of Political Science Research." *The Journal of Politics*, June, 000–000. doi:10.1086/734280.
- Sposito, Italo Beltrão, João Paulo Nicolini Gabriel, and Marcel Artioli. 2022. "Como Selecionar Casos a Partir de Diferentes Alegações de Causalidade." *Revista de Sociologia e Política* 30. SciELO Brasil: e022.
- Urminsky, Oleg, Christian Hansen, and Victor Chernozhukov. n.d. "The Double-Lasso Method for Principled Variable Selection." OSF.
- Vick, Fernanda, and Adrián Gurza Lavalle. 2020. "É a Política...a Efetividade Das Conferências e Seus Mecanismos Causais." *Opinião Pública* 26 (3): 556–86. <https://periodicos.sbu.unicamp.br/ojs/index.php/op/article/view/8663884>.