

# Integração de Textos sobre Metodologias de Pesquisa

Manoel Galdino

2024-07-04

## Resumo

Este trabalho examina as implicações da Revolução da Credibilidade para as pesquisas qualitativas causais. O objetivo é demonstrar que a suposta superioridade da metodologia quantitativa sobre a qualitativa, implícita no trabalho de KKV e na visão de muitos cientistas sociais, é sem fundamento e ignora a moderna ciência da inferência causal. Com base na distinção entre identificação causal e inferência estatística, e no uso da inferência Bayesiana, o artigo evidencia que muitas críticas aos métodos qualitativos são improcedentes, especialmente a suposta incapacidade de generalizar resultados, que também está presente em estudos quantitativos. As conclusões destacam que a Revolução da Credibilidade, combinada com a inferência Bayesiana, permite o fortalecimento da pesquisa qualitativa quando seriamente incorporada. O trabalho apresenta ilustrações de metodologias qualitativas aplicadas que apontam esses novos desenvolvimentos, como o rastreamento de processo Bayesiano e queries causais.

## Introdução

O trabalho clássico de @King\_etal\_1994, conhecido como KKV, pretendeu unificar a lógica da pesquisa científica em ciências sociais a partir do paradigma quantitativo em vigor na época em que o livro foi escrito. Ironicamente, ao mesmo tempo em que o livro chegava às prateleiras e era incorporado no discurso científico das ciências sociais, uma revolução nos métodos quantitativos com fins causais se iniciava na economia.

Essa transformação, conhecida como Revolução da Credibilidade, alterou profundamente o paradigma metodológico da inferência causal não apenas na economia, mas também em todas as disciplinas sociais de maneira mais ampla.

A revolução da credibilidade enfatiza a importância de suposições críveis e transparentes para assegurar que os efeitos causais identificados sejam confiáveis, aproximando-se dos resultados de experimentos aleatórios controlados. Esta mudança de paradigma, que inicialmente impactou a pesquisa quantitativa, também traz importantes implicações para a pesquisa qualitativa que não foram devidamente apreciadas. Em vez de classificar os métodos qualitativos como intrinsecamente inferiores, o presente trabalho mostra que o entendimento produzido pela revolução da credibilidade sobre inferência causal coloca muitas das críticas às pesquisas qualitativas como infundadas e baseadas em mal-entendidos sobre o que constitui uma inferência causal válida.

Em paralelo à revolução da credibilidade, a inferência estatística, tradicionalmente dominada pelo paradigma frequentista, se abriu à escola Bayesiana com o advento dos modernos computadores pessoais. E uma característica da inferência Bayesiana é tornar supérflua a necessidade de amostras grandes para se fazer inferência.

Como mostramos no presente trabalho, esses dois desenvolvimentos (revolução da credibilidade e inferência Bayesiana) tornam em certo sentido obsoleto o paradigma sob o qual KKV orientaram sua tentativa de unificar a ciência. Ainda assim, o eco do clássico de metodologia de @King\_etal\_1994 ainda se faz ouvir, especialmente para pesquisadoras que empregam métodos qualitativos.

Frequentemente enfrentam críticas que apontam para supostas limitações metodológicas da pesquisa qualitativa, sugerindo que as abordagens quantitativas seriam mais robustas e confiáveis quando se trata de inferência causal. Este trabalho visa questionar essas críticas à luz da chamada revolução da credibilidade e da inferência Bayesiana, e colocar em bases mais sólidas as diferenças quali-quantitativas.

Mais especificamente, em primeiro lugar o presente trabalho mostra como a Revolução de Credibilidade separou a identificação causal – investigação das suposições necessárias para que uma quantidade causal qualquer possa ser estimável –, da estimação estatística e técnicas de inferência estatística. Ao realizar essa separação, muitas das críticas feitas aos métodos qualitativos, em particular suposta incapacidade de generalização, é inválida e deriva-se de incompreensão entre a distinção de identificação causal e inferência estatística.

Feita essa distinção, mostramos também que outra grande transformação no mundo da pesquisa quantitativa, o advento da inferência Bayesiana, permite superar eventuais limitações de pesquisas com  $n$  pequeno existentes no paradigma frequentista [Vandeschoot\_etal\_2021]. Em outras palavras, mostramos como o uso da inferência Bayesiana permite que as pesquisas qualitativas possam enfrentar o problema da inferência com o mesmo rigor que a pesquisa quantitativa no que tange à inferência causal, não restando mais qualquer pretensão de superioridade da pesquisa quantitativa sobre qualitativa.

Para não fazer apenas uma discussão teórica, apresentamos duas metodologias aplicadas que ilustram o argumento metodológico do texto, o rastreamento de processo Bayesiano de Fairfield\_Charman\_2022 e a abordagem de *queries* causais de Humphreys\_Jacobs\_2023. Ambas apontam um caminho possível pelo qual os métodos qualitativos podem se desenvolver e serem aplicados nos próximos anos.

Por fim, apresentamos também a moderna discussão sobre generalização a partir do conceito de transportabilidade e como ele pode ser usado igualmente por pesquisas qualitativas e quantitativas, ou ainda idealmente, sob métodos mistos.

Portanto, este trabalho contribui para um debate mais equilibrado sobre a metodologia nas ciências sociais, destacando como a revolução da credibilidade pode enriquecer a pesquisa qualitativa ao esclarecer as condições necessárias para a identificação causal. Estabelecidas essas condições, apresentamos a utilização da inferência Bayesiana como a solução “natural” para inferência estatística rigorosa com  $n$  pequeno. Desse modo, esperamos dissipar críticas infundadas e redirecionar os esforços dos pesquisadores para questões metodológicas realmente relevantes da pesquisa aplicada em ciências sociais.

## Revolução da Credibilidade

A revolução da credibilidade na economia [Angrist&Pischke\_2010; Forozish\_2024; Goldsmith\_2024] impactou várias disciplinas que lidam com dados observacionais, incluindo a ciência política. Um dos trabalhos pioneiros que estabeleceram a agenda para essa revolução é o artigo de Leamer\_1983, “Let’s take the con out of econometrics”, onde o autor critica a prática padrão de especificações econométricas múltiplas para controlar vieses de variável omitida, argumentando que tais práticas não produzem resultados confiáveis.

Respondendo ao desafio de Leamer, vários autores desenvolveram desenhos de pesquisa com suposições mais críveis e transparentes [card\_22; Angrist\_Pischke\_2010; Angrist\_Pischke\_2009; Angrist\_Krueger\_1991; Card\_Krueger\_1994]. Esses estudos buscaram assegurar que os efeitos causais fossem reais e se aproximassem dos resultados de experimentos aleatórios controlados, elevando o padrão de inferência causal [Rubin\_1974].

A revolução da credibilidade se espalhou para outras disciplinas, como sociologia [Lundberg\_etal\_2021], estudos russos [Libman\_2023], saúde [Glied\_2021] e, claro, ciência política [Samii\_2016; Keele\_2015a; Keele\_2015b; Grimmer\_2015]. Os impactos na pesquisa quantitativa foram imediatos, com a redução do uso de regressões com muitas variáveis em favor de desenhos quase-experimentais, como diferenças em diferenças, regressão descontínua e variáveis instrumentais, para identificar relações causais com maior precisão. Ensaios aleatórios controlados (RCTs) passaram a ser vistos como o padrão-ouro para inferências causais, e houve um desenvolvimento de novas ferramentas estatísticas para implementar essas metodologias.

Para nós, é importante destacar que, sob essa perspectiva, a inferência causal é uma consequência dedutiva

de suposições críveis, aproximando-se da visão de causalidade de Hume, onde a causalidade não pode ser observada diretamente. O trabalho do cientista social, portanto, é desenhar estudos com suposições críveis que levem à “identificação causal”.

### **Identificação Causal**

Identificação causal refere-se à capacidade de um desenho de pesquisa determinar um estimador específico, como o efeito causal médio (ATE - Average Treatment Effect) ou o efeito do tratamento sobre os tratados (ATT - Average Treatment on the Treated). A identificação não depende do tamanho da amostra, mas sim da estrutura metodológica do estudo e de suposições críveis.

A preocupação com identificação causal, destacada pela revolução da credibilidade, implicou uma ênfase na validade interna dos estudos. A validade interna se refere à precisão com que um estudo pode identificar um efeito causal na sua amostra específica. Por outro lado, a validade externa refere-se à capacidade de generalizar os achados para outras populações e contextos [Findley\_etal\_2021]. Essa distinção introduzida por Campbell\_17 é crucial, mas a revolução da credibilidade muitas vezes sobrevalorizou a validade interna em detrimento da validade externa [Findley\_etal\_2021]. Voltaremos a esse ponto na discussão sobre transportabilidade. Por ora, o que importa destacar é que a validade interna é algo que se determina anteriormente a qualquer trabalho de inferência estatística.

### **Soluções Práticas para Inferência em Amostras Pequenas**

Não espero, contudo, que alguém treinado na metodologia KKViana seja facilmente convencido apenas por argumentos teóricos sobre a viabilidade de pesquisas causais qualitativas, baseando-se no argumento de que a identificação causal é ortogonal às questões de inferência. Afinal, isso não significa necessariamente que a inferência causal pode ser realizada na prática para tamanhos amostrais pequenos, mesmo que um modelo seja identificado. Um cético pode argumentar que ainda será necessário um grande número de casos para estimar o efeito causal de interesse.

Portanto, é essencial apresentar soluções práticas para o problema da inferência com amostras pequenas. Talvez ironicamente, é na estatística que está a solução para esse problema. Tradicionalmente, a inferência estatística adotou o paradigma frequentista, que depende de propriedades assintóticas dos estimadores, isto é, de quando o tamanho amostral vai para o infinito. Contudo, há desde o começo da disciplina da estatística um outro paradigma alternativo, e que vem ganhando proeminência aplicada nas últimas décadas que é a inferência Bayesiana.

### **Inferência Bayesiana**

Na estatística Bayesiana, a quantificação da incerteza depende de uma distribuição de probabilidade a priori, que usualmente é interpretada como a incerteza da pesquisadora antes de observar evidência empírica, e uma verossimilhança, que é uma modelagem do processo de geração de dados. O teorema de Bayes, que dá nome à abordagem estatística, nos diz como combinar de maneira rigorosa a priori e a verossimilhança, para obtermos uma distribuição de probabilidade a posteriori (isto é, após observar a evidência empírica) sobre as quantidades de interesse.

A rigor, nessa abordagem, podemos quantificar incerteza até mesmo com zero observações, refletidas na priori. E com uma observação apenas já podemos computar a verossimilhança e calcular a posteriori. E não há diferença formal entre  $n$  pequeno ou grande. O impacto do tamanho amostral é apenas em reduzir a incerteza a posteriori. É possível mostrar que, sob condições bastante gerais de regularidade, a distribuição a posteriori converge para a distribuição verdadeira à medida que o tamanho amostral vai para infinito. Em outras palavras, a incerteza se reduz com  $n$  maior, mas a rigor nada impede de se estimar qualquer quantidade de interesse com um  $n$  pequeno.

### **Fundamentos da Probabilidade Bayesiana**

Para facilitar a compreensão das novas metodologias que integram inferência Bayesiana com inferência causal em estudos qualitativos, é útil apresentar uma rápida introdução formal à maquinaria Bayesiana.

## Regra do Produto

O teorema de Bayes é na verdade uma mera aplicação da regra do produto de probabilidade, de forma que vale a pena começar por esta regra, para então formular o teorema de Bayes.

A probabilidade conjunta de dois eventos  $A$  e  $B$  pode ser expressa como  $p(AB) = p(A)p(B|A)$  ou  $p(B)p(A|B)$ . Para três eventos  $A$ ,  $B$  e  $C$ , a probabilidade conjunta  $p(ABC)$  é decomposta em uma série de probabilidades condicionais:  $p(ABC) = p(A)p(B|A)p(C|AB)$ .

**Teorema de Bayes** O Teorema de Bayes permite combinar conhecimento a priori com dados observados para atualizar a crença sobre um parâmetro ou evento. Formalmente, seja  $H$  uma hipótese causal, e  $E$  a evidência ou conjunto de evidências coletada.

Estamos interessados em combinar quantificar a probabilidade da hipótese ser verdadeira, dada a evidência. Dado que, pela regra do produto,  $p(E|H) = p(H)p(E|H) = p(E)p(H|E)$ , podemos rearranjar a igualdade e obter:  $p(H|E) = \frac{p(H)p(E|H)}{p(E)}$ . Aqui,  $p(H)$  é a probabilidade a priori da hipótese,  $p(E|H)$  é a verossimilhança, isto é, uma quantificação de quanto a evidência é mais ou menos provável, dada a hipótese sobre o mecanismo causal, e  $p(E)$  é chamada de constante normalizadora e mede a probabilidade a priori da evidência.

**Constante Normalizadora** Aplicando a regra da probabilidade total, podemos calcular  $P(E)$  como:  $P(E) = p(H)p(E|H) + p(\neg H)p(E|\neg H)$ . Portanto, posso expressar a probabilidade não-condicional da evidência como uma série de probabilidades condicionais, ponderadas pela probabilidade das hipóteses (no exemplo, a hipótese formulada e sua negação).

## Função de Verossimilhança

A função de verossimilhança é a probabilidade dos dados observados tratada como uma função dos parâmetros. Pode ser escrita como  $L(\theta|x_1, x_2, \dots, x_n) = p(x_1, x_2, \dots, x_n|\theta)$ , onde os dados são fixos e o parâmetro  $\theta$  é aleatório. No caso mais simples de uma hipótese, escrevemos  $P(E|H)$ . O importante é notar que, apesar de escrever  $P$ , não se trata propriamente de uma probabilidade, mas de uma verossimilhança.

## Soluções Práticas para Inferência em Amostras Pequenas

Na próxima seção, apresentaremos as soluções de duas abordagens recentes que utilizam a metodologia Bayesiana para estimar quantidades causais em pesquisas qualitativas: uma desenvolvida no livro *Integrated Inferences* de @Humphreys\_Jacobs\_2023 (ver também @Humphreys\_Jacobs\_2015) e outra no livro *Social Inquiry and Bayesian Inference* de @Fairfield\_Charman\_2022 (ver também @Fairfield\_Charman\_2019; @Fairfield\_Charman\_2017).

Essas soluções deixam claro e sem sombra de dúvidas o argumento do trabalho de que o problema de identificação é completamente distinto e ortogonal ao problema da inferência estatística.

## Rastreamento de Processo Bayesiano

O rastreamento de processos bayesiano é uma abordagem robusta para inferência causal em estudos qualitativos. Utilizando a probabilidade bayesiana, podemos atualizar nossas crenças sobre hipóteses causais à medida que novas evidências são coletadas. Este método é particularmente útil em contextos onde as evidências são escassas ou os processos causais são complexos.

Assim, envolve a especificação de hipóteses  $H_i$  e suas probabilidades a priori  $P(H_i)$ . Devemos identificar as evidências disponíveis e construir a verossimilhança  $P(E|H_i)$  para cada hipótese. As comparações de hipóteses são feitas usando as odds a posteriori, de forma a não precisa computar a constante normalizadora:

$$\frac{P(H_i|E)}{P(H_j|E)} = \frac{P(H_i)P(E|H_i)}{P(H_j)P(E|H_j)}$$

Vamos tratar como cada um dos componentes da fórmula acima (priori e verossimilhança) são formulados na prática.

## Definição de Priors

A definição de priors pode ser feita por meio da elicitacão de experts, uso de priors não-informativas e priors informativas definidas pela pesquisadoras.

A elicitacão de experts envolve a consulta a especialistas e utilização de métodos para transformar o conhecimento deles em distribuições de probabilidade. Como tais pessoas não costumam saber traduzir seus conhecimentos em distribuição de probabilidade, a literatura dessa área tem desenvolvido métodos para extrair esse conhecimento e quantificá-lo em distribuições de probabilidade (Ohagan\_2019, @Albert\_etal\_2012, Ohagan\_etal\_2006, Ohagan\_1998).

Priors não-informativas são a forma mais básica e tradicional de definição de priors [@Ohagan\_2010]. A ideia é escolher uma priori que torne todas as hipóteses a priori igualmente prováveis, seguindo o princípio da razão insuficiente [@Kass\_Wasserman\_1996].

Uma terceira possibilidade é o uso de priors informativas, que representem o conhecimento da pesquisadora, que pode advir de conhecimento substantivo ou de resultados de pesquisas prévias como meta-análises ou estudos quantitativos prévios [@Gelman\_etal\_2017; @Gelman\_2009].

## Verossimilhanças

A verossimilhança avalia a plausibilidade de observar uma evidência  $E$  sob a hipótese  $H_i$ . Os autores recomendam adaptar a ideia de decibéis, que utilizamos para classificar o volume de um som, para avaliar o peso de uma evidência. Ou seja, deveríamos usar logaritmos (os decibéis são calculados com logaritmos) para calibrar o peso das evidências:

$$10 \log_{10} \left( \frac{P(E|H_i)}{P(E|H_j)} \right)$$

Para ver a utilidade de se utilizar decibéis para ponderar o peso das evidências, os autores analisam um exemplo introduzido por Bennet (2015), no qual o autor considera um *smoking gun* se  $P(E|H_j) = .05$  e  $P(E|H_i) = .2$ . Aplicando o logaritmo, isso dá cerca de 6db. Segundo @Fairfield\_Charman\_2017, um volume de 6db é saliente, mas estaria longe de ser um *smoking gun*.

## Evidências

Na análise estatística tradicional, é em geral simples determinar quando uma observação termina e outra começa. No caso de estudos qualitativos, em especial rastreio de processo, esse passo é menos trivial.

A definição de evidências é crucial e pode incluir informações de diferentes fontes ou observações correlacionadas. No Bayesianismo, podem ser consideradas evidências de outros casos similares. Evidências devem ser suficientemente distintas para favorecer hipóteses diferentes.

## Hipóteses Rivals

As hipóteses devem ser rivais, ou seja,  $P(H_i) + P(H_j) = 1$ . A negação lógica não é recomendada, pois inclui infinitas hipóteses contraditórias. Uma das limitações da abordagem de rastreio de processo Bayesiana é quando a pesquisadora considera a possibilidade de múltiplas causas, pois é difícil formulá-las como hipóteses rivais.

## Inferências Integradas

O trabalho de @Humphreys\_Jacobs\_2023 apresenta o que eles chamam de queries causais, que consiste na utilização de Directed Acyclic Graphs (DAGs), tal como desenvolvida por Pearl, juntamente com inferência Bayesiana, para estimar quantidades causais com métodos qualitativos. O termo inferência integrada é porque, ao utilizar metodologias originariamente quantitativas, permite integrar qualit-quantit, produzindo assim desenhos de pesquisa com métodos mistos. Aqui interessa para nós o aspecto qualitativo da abordagem, então será nosso foco.

Um primeiro aspecto que a metodologia de @Humphreys\_Jacobs\_2023 deixa claro é que é necessário, para fins práticos, considerar todas as variáveis da pesquisa quali como binárias. Isso faz sentido, posto que seria inviável mensurar quantidades contínuas e relacioná-las estatisticamente com amostras pequenas. Ou seja, a variância potencial seria muito grande, tornando inviável a estimação.

Um segundo aspecto é que, como é costumeiro, é mais fácil modelar as relações causais como determinísticas, ou seja, um caso possui ou não relação causal entre variáveis, não cabendo pensar probabilisticamente. Isso, contudo, não é uma limitação muito relevante, pois a quantificação da incerteza via Bayes significa que poderemos falar de probabilidade do efeito causal existir. Ou seja, a relação é determinística, mas o nosso conhecimento sobre a relação causal é probabilístico, o que é compatível com boa parte das ontologias sociais.

A suposição de que a relação causal é determinística e binária leva a ideia de que cada caso pode ser classificado em um tipo causal. Os tipos causais podem ser classificados em quatro categorias: adverso, benéfico, crônico e destinado. Cada tipo representa uma relação causal distinta entre tratamento e resposta. Por exemplo, indivíduos adversos melhorariam apenas se não recebessem o tratamento, enquanto os benéficos melhorariam apenas se o recebessem. Os crônicos permanecerão doentes independentemente do tratamento, e os destinados melhorarão independentemente do tratamento. Esse modelo pode ser facilmente generalizado para múltiplas causas, com uma pequena modificação na notação, a qual o leitor interessado pode encontrar no livro de Humphreys e Jacobs.

Para aplicar essa estrutura teórica, utilizamos modelos de queries causais. Esses modelos nos permitem investigar efeitos causais médios, causas ao nível de casos (case-level causal analysis) e caminhos causais. Uma query causal é um algoritmo que recebe um modelo  $M$  como entrada (especificado na forma de um DAG) e retorna uma quantidade  $Q(M)$  como saída. Existem quatro queries causais chave que são fundamentais para essa análise e respondem a questões distintas: - Efeitos causais ao nível de caso (case-level). - Atribuição causal ao nível de caso. - Efeitos causais médios (ATE). - Caminhos causais.

### **Efeito Causal ao Nível do Caso**

Perguntas de pesquisa frequentemente investigam se  $X$  tem um efeito causal em  $Y$  em casos específicos. Por exemplo, se houvesse uma crise econômica no Brasil hoje, Lula sofreria impeachment? Em termos contrafactuais, a questão é se, ao intervir exogenamente no valor de  $X$ , o valor de  $Y$  mudaria. Esse tipo de query nos ajuda a entender as implicações de mudanças específicas em variáveis causais. O modelo de queries causais aqui apresentado permite responder a esse tipo de pesquisa, tipicamente qualitativas, de maneira quantitativamente precisa, a partir de estudo de caso.

### **Atribuição Causal ao Nível do Caso**

Além de investigar se  $X$  tem um efeito causal, também é importante determinar se  $X$  de fato causou  $Y$  em casos específicos. Por exemplo, a crise econômica causou o impeachment da Dilma em 2016? Em termos contrafactuais, a questão é se, dado os valores que  $X$  e  $Y$  assumiram, o valor de  $Y$  seria diferente se o valor de  $X$  fosse diferente. Este tipo de análise é crucial para entender a relação direta entre causas e efeitos em contextos específicos.

### **Efeito Causal Médio**

Podemos também explorar efeitos causais médios em populações. Para tratamentos e respostas binárias, o efeito causal médio é a diferença entre a proporção de casos em que o efeito é benéfico e a proporção de casos em que o efeito é negativo. Esta abordagem nos permite entender o impacto geral de tratamentos em grandes grupos. Essa é um dos casos em que a abordagem qualitativa mais facilmente é integrada com estudos quantitativos.

### **Caminhos Causais**

Em casos onde estabelecemos que  $X$  causou  $Y$ , é relevante investigar se isso ocorreu via um mediador  $M$ . Em notação de resultados potenciais, perguntamos se  $Y(X = x, M = M(X = 1))$  é maior do que

$Y(X = x, M = M(X = 0))$ . Este tipo de query nos ajuda a mapear as vias por meio das quais os efeitos causais se manifestam.

### **Causas de Fato/Reais/Atuais (Actual)**

A definição de causalidade contrafactual típica dos modelos de resultados potenciais pode gerar paradoxos, como no seguinte exemplo. Suponha que Suzy e Bob jogam pedras em uma garrafa. Ambos jogam a pedra no alvo, de modo que ambas atingiram a garrafa, exceto que a de Suzy quebra a garrafa e a de Bob chega um pouco depois. Nesse caso, é óbvio que a pedra de Suzy foi a causa da quebra da garrafa. Porém, na noção de causalidade contrafactual, diríamos que a pedra de Suzy não foi a causa da quebra da garrafa, pois a causalidade é definida como a diferença entre o que aconteceu de fato e o que aconteceria no contrafactual. Nesse caso, se Suzy não tivesse jogado a pedra, a garrafa quebraria do mesmo modo. Assim, a utilização de queries causais permite tratar desse tipo de causa, algo não possível na abordagem mainstream de resultados potenciais. E para distingui-la da definição de causa contrafactual, os autores chamam de causas de fato (ou atuais) este tipo de causa, cujo efeito depende de outra variável, como a pedra de Bob não atingir a garrafa antes. Este conceito nos permite diferenciar entre causas diretas e indiretas em cenários complexos.

### **Comparando as Abordagens**

As duas metodologias aqui apresentadas são exemplos de desenvolvimento recentes de utilização de inferência Bayesiana para estudos qualitativos. Os trabalhos de Fairfield e Charman têm como objetivo formalizar o rastreamento de processos, metodologia qualitativa que tem se desenvolvido bastante nas últimas décadas. Ela é particularmente útil quando as hipóteses são de fato rivais e permite avaliar hipóteses causais concorrentes para explicar fenômenos sociais nos quais apenas o rastreamento de processo poderá recuperar o efeito causal de interesse.

O modelo de queries causais de Humphreys e Jacobs é mais genérico, podendo ser aplicado a muitos diferentes tipos de pesquisas qualitativas, incluindo rastreamento de processo. Também utiliza inferência Bayesiana para estimação e quantificação da incerteza, mas não possui a limitação de restringir-se a situações de hipóteses rivais, admitindo hipóteses complementares. Por outro lado, é limitado a variáveis categóricas (pode ser estendido a mais de duas categorias, mas rapidamente se torna inviável em termos de implementação algorítmica à medida que o número de tipos causais aumenta). Além disso, ao não incorporar a ideia de decibéis para ponderar o peso das evidências, perde uma heurística importante do método advogado por Fairfield e Charman.

Como são metodologias novas, aperfeiçoamentos e mesmo a mistura de ambas podem vir a ser desenvolvimentos possíveis. Por hora, importa salientar que ambas já estão começando a ser aplicadas, embora requeiram treinamento longo e extenso, como os próprios autores reconhecem em seus trabalhos.

### **Transportabilidade**

Como vimos, a inferência causal depende primeiramente de condições para a identificação causal. Superada essa questão, a inferência estatística pode ser feita por meio de métodos Bayesianos para estudos com  $n$  pequeno. Contudo, isso garante apenas a validade interna do estudo, tal como em desenhos de pesquisa causais quantitativos. Ou seja, ambas metodologias sofrem da mesma incapacidade de generalização para outros contextos ou populações, no que é conhecido como validade externa.

Nesse sentido, uma suposta incapacidade de generalização devido ao número reduzido de casos analisados é sem fundamento. Ambos tipos de estudo em geral sofrem dos mesmos problemas de generalização, refletidos na ausência de garantias de que há validade externa.

A distinção entre validade interna e externa foi introduzida pela primeira vez por @campbell\_17, no contexto de estudos experimentais. Validade interna, na definição original, dizia respeito à capacidade de um experimento detectar o efeito causal de interesse na amostra em questão. Hoje em dia, dizemos que um estudo (não apenas experimental) possui validade interna se seu desenho, condução (incluindo a coleta de dados) e análise permite responder às perguntas de pesquisa adequadamente para a amostra estudada (@andrade\_18). A revolução da credibilidade formalizou as condições para o estabelecimento da validade interna de um estudo.

Contudo, a ideia de validade externa continuou vaga por muito mais tempo, e apenas recentemente o conceito tem avançado em direção a uma formalização das condições nas quais a validade externa pode ser crivelmente garantida, na forma do conceito de transportabilidade.

Para discutir como essa abordagem permite mostrar que os limites da pesquisa quantitativa causal aderente ao paradigma da revolução da credibilidade são similares aos estudos qualitativos, convém apresentar alguns termos introduzidos pela literatura que discute transportabilidade [Pearl\_Bareinboim\_2011, Pearl\_Bareinboim\_2022].

Em primeiro lugar, precisamos atentar para o fato de que uma dada pergunta de pesquisa pressupõe, implícita ou explicitamente, um alvo, um estudo e uma análise. Tratemos inicialmente dessas três categorias quando aplicadas à população, e então à uma dada amostra, a partir de um exemplo.

Imagine que estamos interessados em entender como a liberação de emendas impacta (causalmente) a taxa de votação com o governo de deputados que tiveram emendas liberadas. A população alvo pode ser formada, por exemplo, por votações futuras sob o mesmo governo, ou sob governos futuros. Ou seja, a população alvo é aquela sob a qual a pesquisadora gostaria de utilizar os resultados da análise. Isso é particularmente relevante em questões de política pública, no qual a população alvo é a população que efetivamente será impactada por uma política pública a qual o estudo está procurando avaliar o impacto de uma intervenção. A população do estudo é a população hipotética que a amostra representa. Digamos que uma pesquisadora realizou um experimento com estudantes universitários. Se a população alvo pode ser as pessoas adultas de um país, a população hipotética pode ser, talvez, a população de estudantes universitários do país, ou a população de estudantes universitários matriculados em cursos iguais ou similares no país ou quaisquer outras variações que possamos pensar (universidade pública ou privada, no estado onde foi realizado o experimento etc.). A população do estudo, por ser hipotética, em geral não é observável nem necessariamente bem-definida. No exemplo das relações executivo-legislativo, não é clara qual a população de votações que o estudo representa, nem qual a população de liberações de emendas, por exemplo. Por fim, a população da análise é, similarmente, a população hipotética da amostra efetivamente analisada. Por exemplo, o estudo pode remover votações legislativas unânimes, ou em que não houve votação nominal, ou apenas para um período de tempo específico. Cada uma dessas escolhas significa que a população analisada pode diferir da população do estudo. Em geral a literatura subsume essas duas últimas categorias em uma única, na forma da população do estudo. Porém, como apontam Degtiar\_Rose\_2023, a rigor são três categorias distintas que possuem características específicas. Mas, seguindo a literatura, iremos trabalhar com as duas primeiras categorias apenas.

Todo o problema de validade externa, portanto, diz respeito à necessidade de fazer inferência de uma população para outra, isto é, da população do estudo (que aqui inclui a população de análise) para a população alvo. Se o efeito causal na população de estudo for diferente do efeito causal na população alvo e essa diferença não for quantificada ou estimada, então não saberemos dizer se e quanto as conclusões feitas na população de estudo são válidas para inferências na população alvo.

Raramente, contudo, temos acesso a toda a população (que pode ser potencialmente infinita), de modo que precisamos trabalhar com uma amostra. E essa amostra sempre será definida a partir da população de estudo, que em geral seria diferente de uma amostra obtida da população alvo para além de variações inerentes ao processo de amostragem.

A estimação do efeito causal se inicia, sempre, pela definição de um estimando [Little\_Lewis\_2021; Lundberg\_etal\_2021]. Maldonado\_Greenland\_2002.

Um estudo ideal seguiria o seguinte caminho: definição de uma população alvo -> amostra aleatória da população alvo seria coletada, construindo a amostra do estudo, alocação aleatória de tratamento e controle entre unidades da amostra (experimento aleatório) e a população do estudo e alvo coincidiriam, e o efeito causal de interesse teria validade interna e externa (Lesko\_etal\_2017).

Na prática, raramente um estudo em ciências sociais segue esse fluxo. O caminho mais comum é coletar uma amostra (por exemplo, com dados administrativos), criando assim uma população do estudo hipotética e não-definível, e outra população alvo, potencialmente diferente da população do estudo. Por se tratar de dados observacionais, uma pesquisa sofisticada metodologicamente se preocupará em mostrar que as



suposições de identificação são críveis, criando assim validade interna, isto é, não há viés na inferência da amostra do estudo para a população do estudo. Nada ou quase nada será dito sobre validade externa.

Os trabalhos de Bareinboim e Pearl [ver @Pearl\_Bareinboim\_2022, @Bareinboim\_Pearl\_2016, @Pearl\_Bareinboim\_2011] utilizam DAGs para demonstrar, matematicamente, as condições nas quais a transportabilidade pode ser feita.

É preciso portanto especificar quais variáveis induzem viés na estimativa para outras populações, e ajustar para variáveis que viesam as estimativas. Mais uma vez, as condições de identificação do efeito causal de interesse em outra população é separado do problema da estimação estatística. E nada impede a pesquisadoras qualitativa de utilizar o framework de queries causais desenvolvido por @Humphreys\_Jacobs\_2023.

Como essa literatura ainda é muito recente, há pouco desenvolvimento nesse sentido na literatura quantitativa e menos ainda na qualitativa. Para os nossos propósitos, importa salientar apenas que a abordagem de DAGs são a base desse tipo de análise.

## **Considerações Finais**